HBase 簡介與實作

David Chiu
2016/07/07

NoSQL

關聯式資料庫

- 安全存儲、管理資料
  - 有效管理磁碟上的資料
- 保持資料的一致性
  - ACID 四原則
- 可以透過標準模型整合資料
  - 使用SQL 操作資料

面對大量資料

- 垂直擴展 (Vertical Scaling – Scale Up)
  - 增加單一台的 CPU, Storage, Memory
- 水平擴展 (Horizontal Scaling – Scale Out)
  - 使用多台機器分散工作

資料表分割

e.g. 用時間切割

查詢作業就可以只針對這個部分去處理，而不用掃描整張資料表，才能找到指定資料

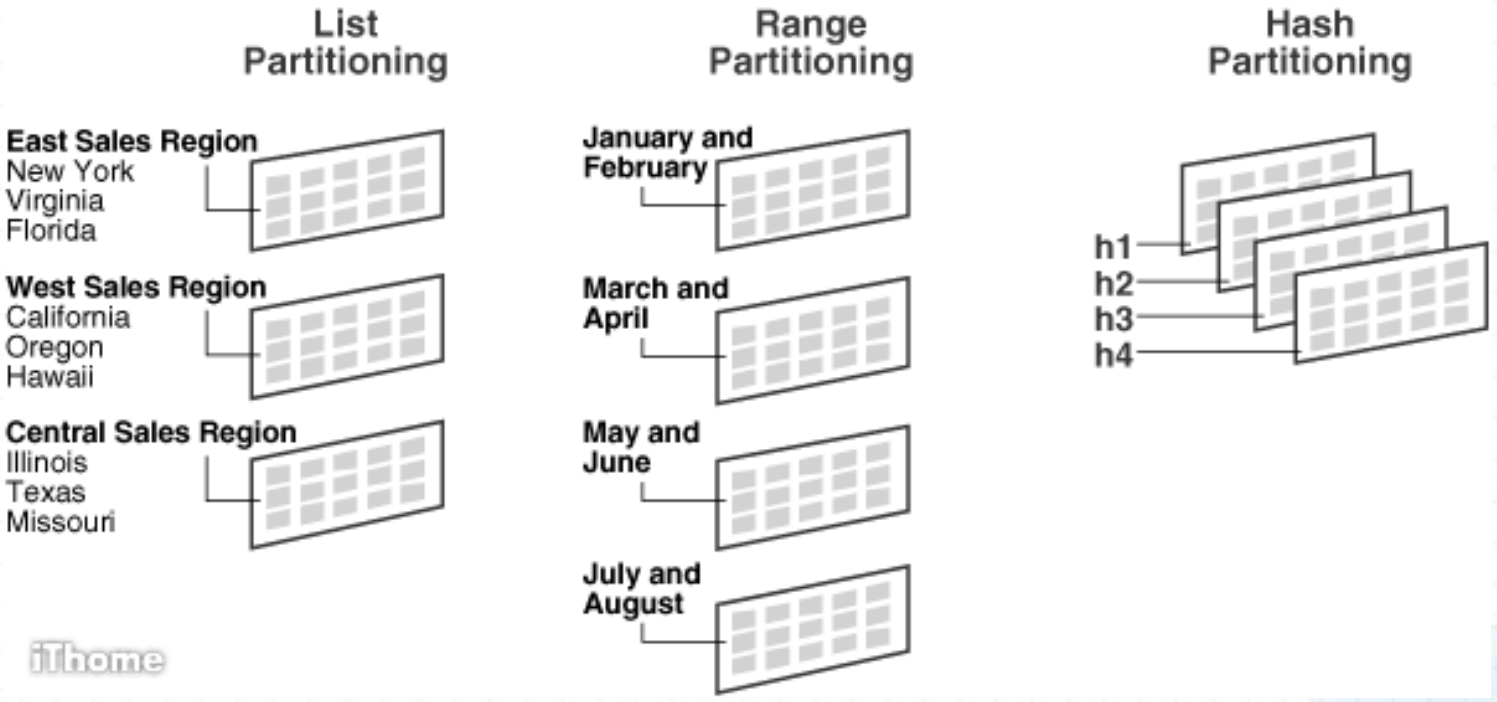

水平分割 (Horizontal Partition)

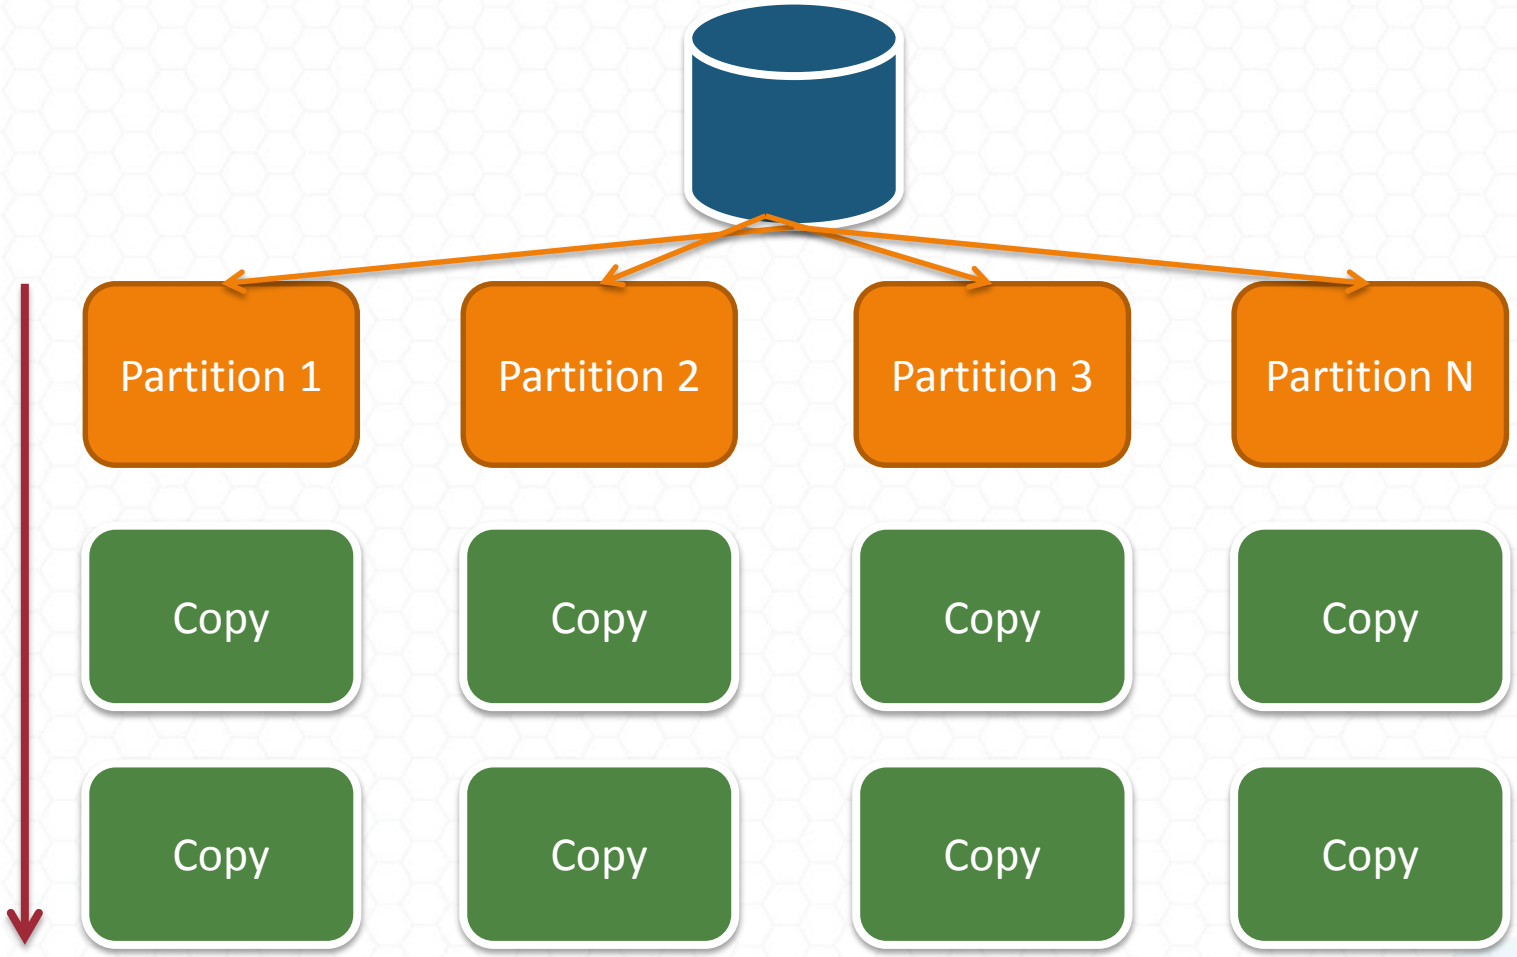

數據路由 – 水平分割

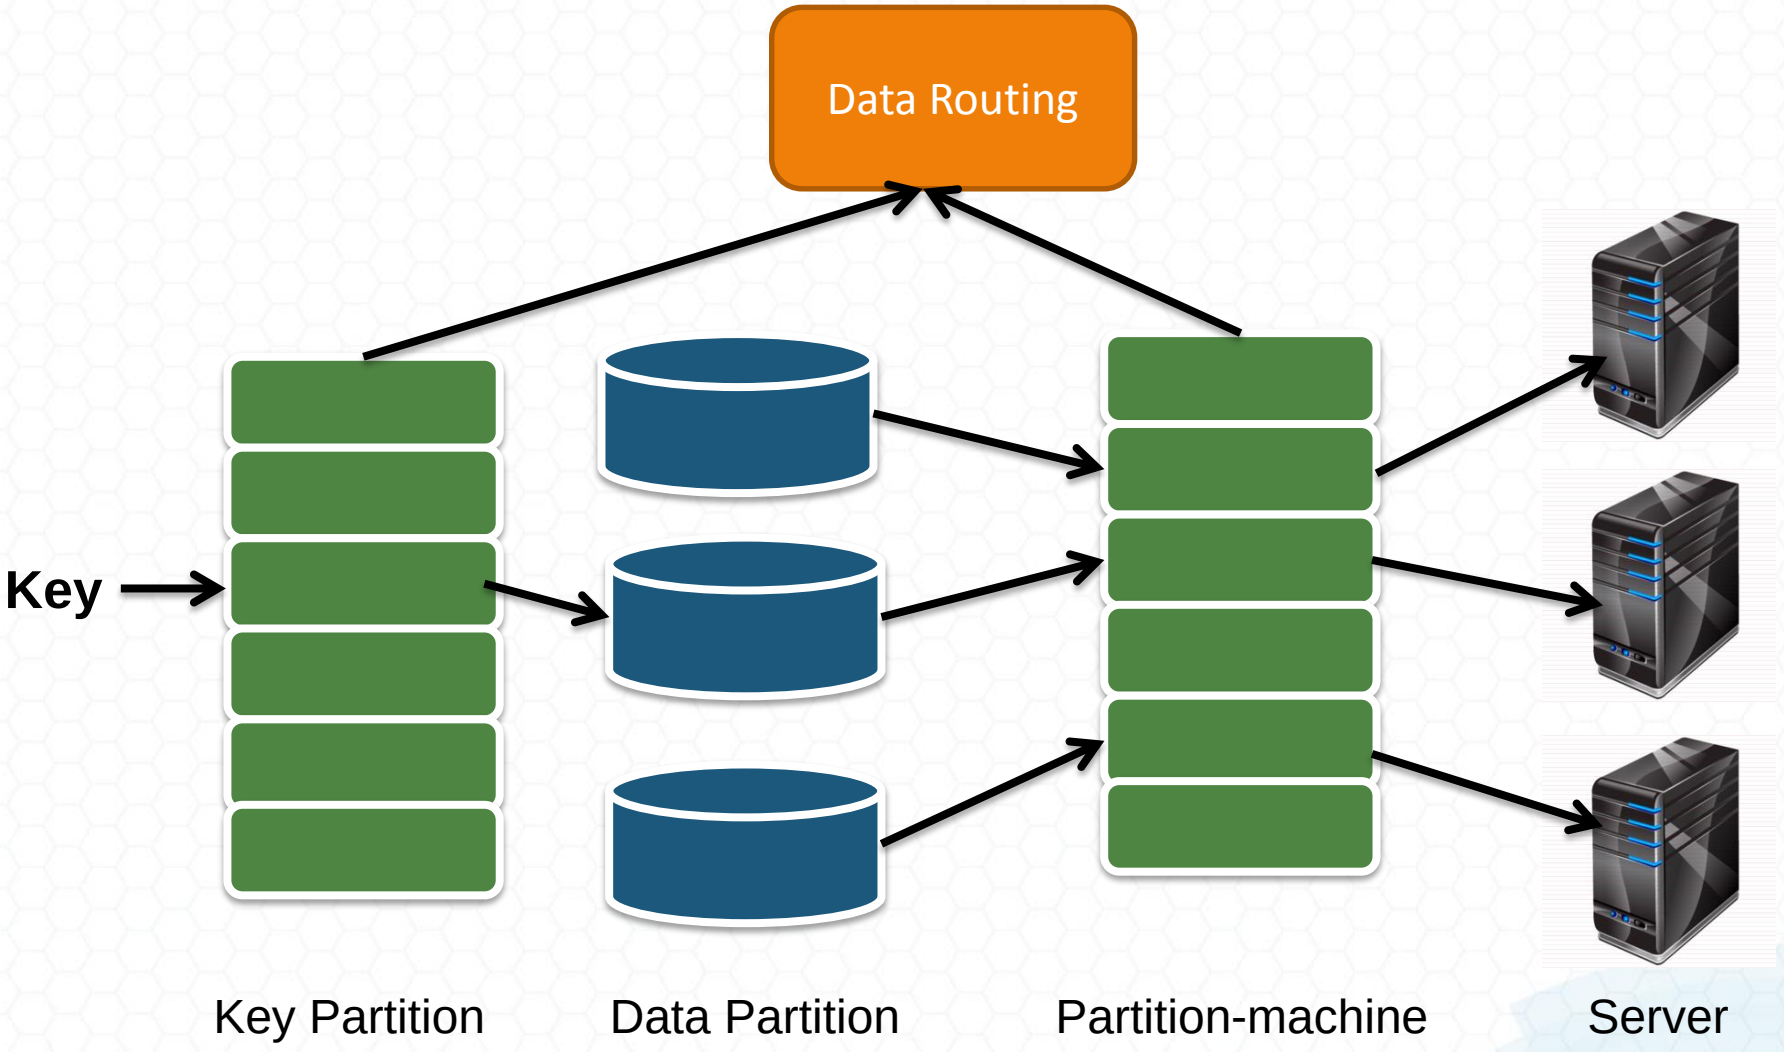
Data Routing
Key
Key Partition
Data Partition
Partition-machine
Server

為什麼要用 NoSQL

NoSQL的出現

- 網路公司的崛起
  - BigTable
  - DynamoDB
- Strozzi NoSQL
  - 用Tab 分割資料
  - 使用shell 操作資料
- Johan Oskarsson舉辦DynamoDB 與BigTable技術討論聚會時所用的名詞

NoSQL

- NoSQL (Not Only SQL)
- 或是指相對於關聯式資料庫而言(MySQL 或 PostgreSQL) 的非關聯式資料庫
- 特性
  - 可以將資料平行分散於叢集中
  - 不使用關聯性模型 (Schema Less)
  - 極具成本效益 (Cost Effective)
  - 開源 (Open Source)

Visual Guide to NoSQL Systems

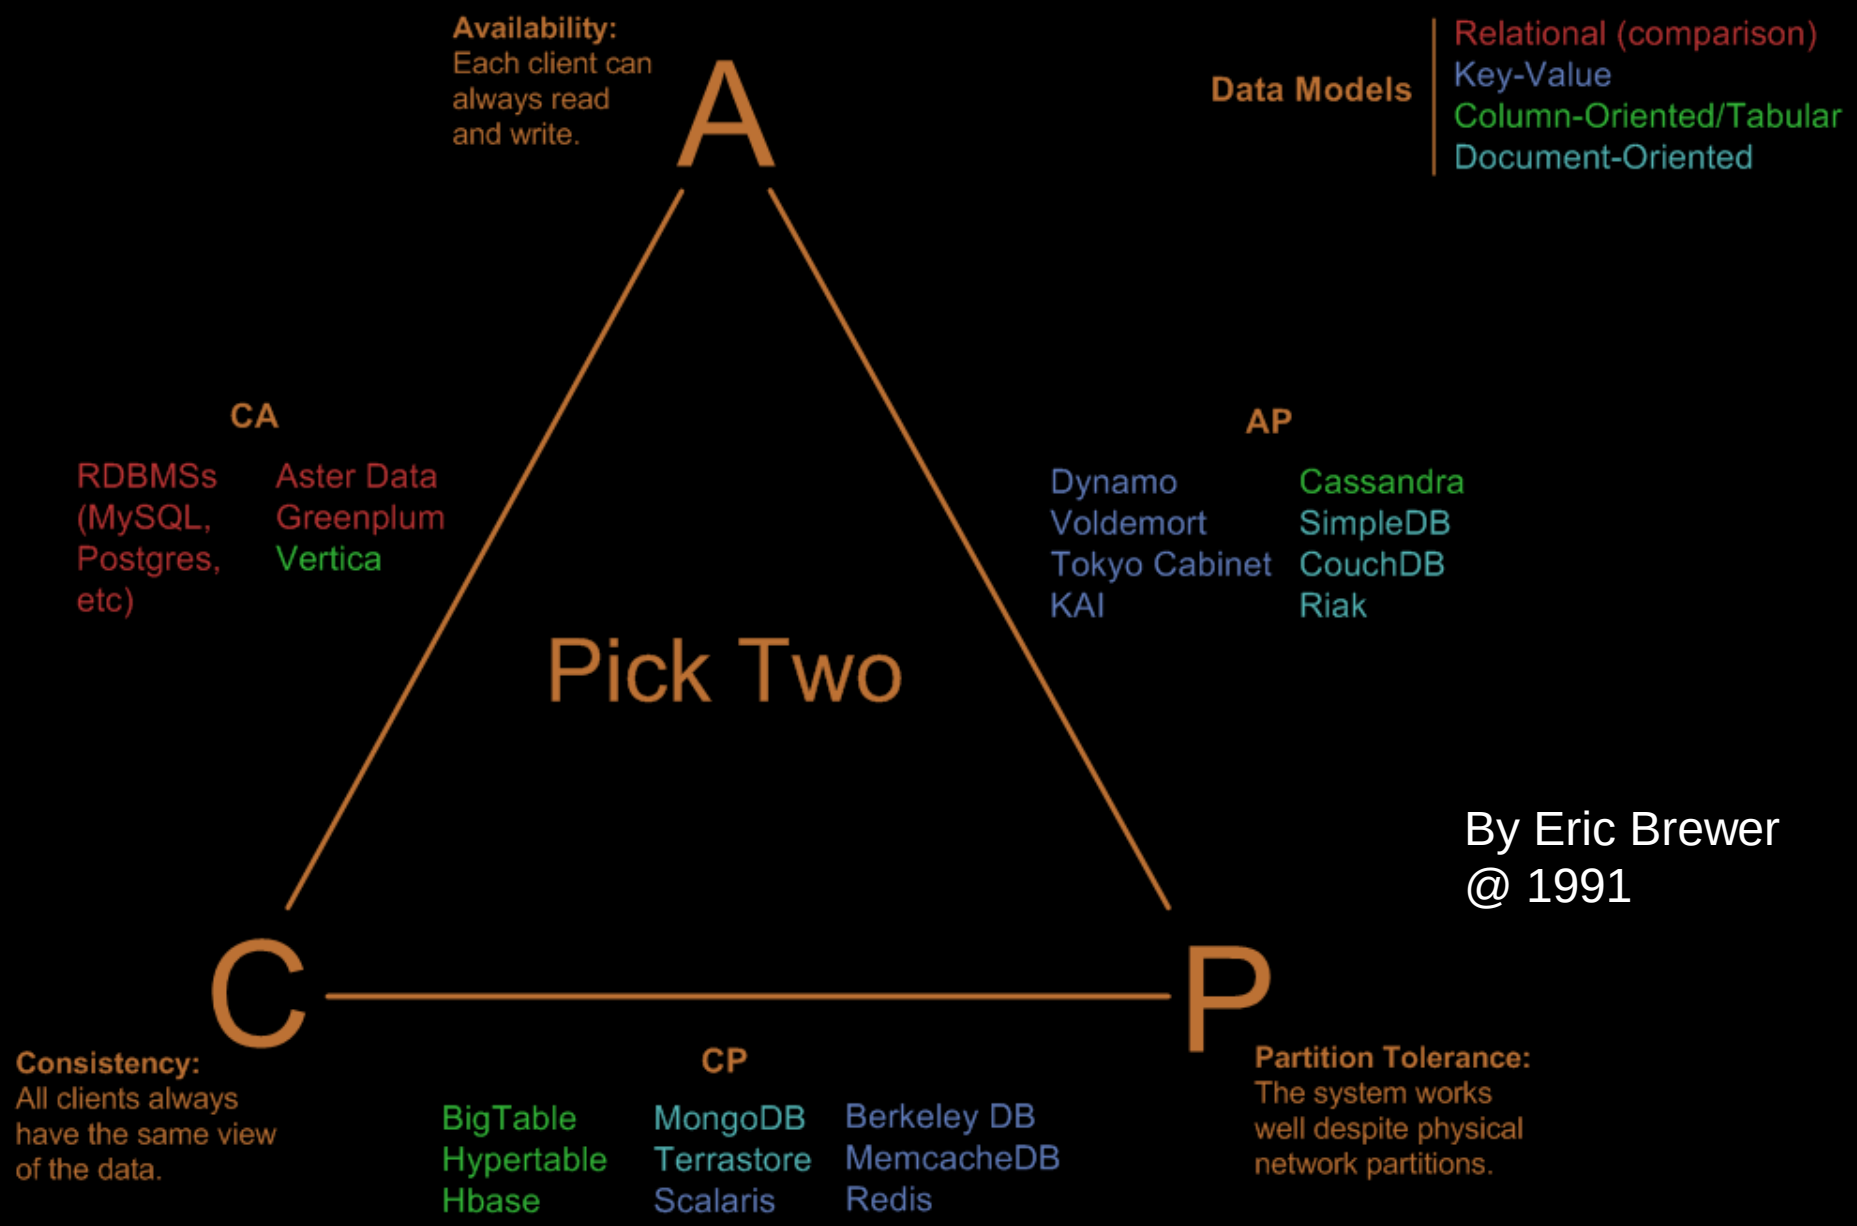

By Eric Brewer
@ 1991

CAP 滿足的情境

- 情境一
  - 資料無副本 -> 必然滿足 C & P
  - 網路無法連通或有機器當機時 -> 部分數據不可被訪問

- 情境二

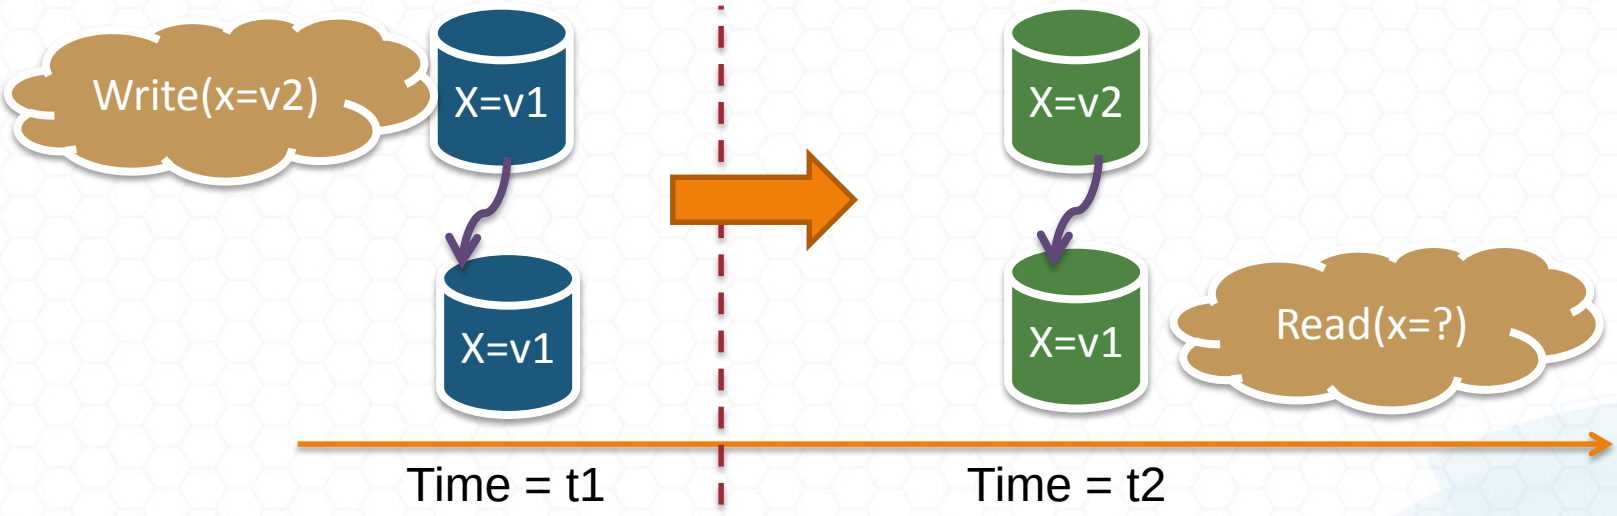

滿足CP的非關聯式案例

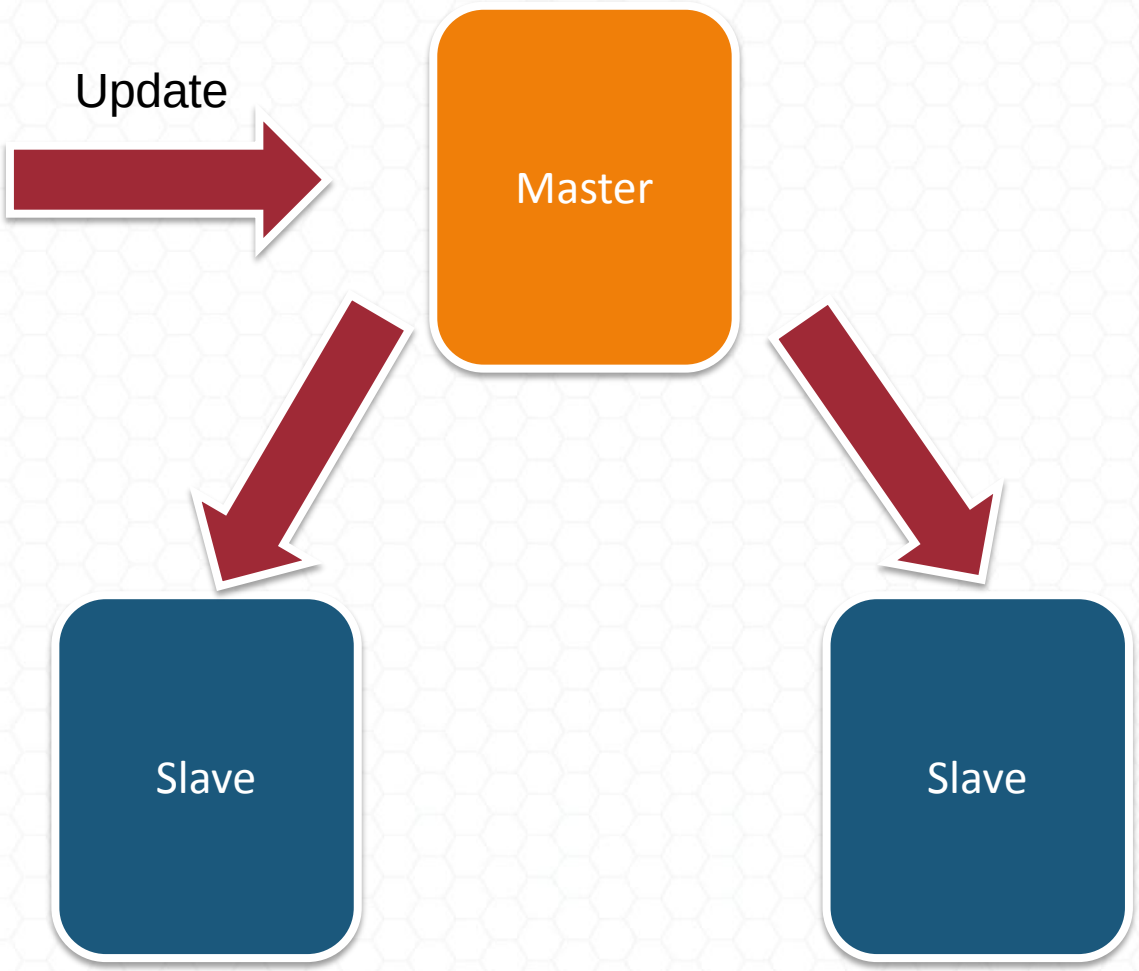

mongoDB

主從式架構

滿足AP的非關聯式案例

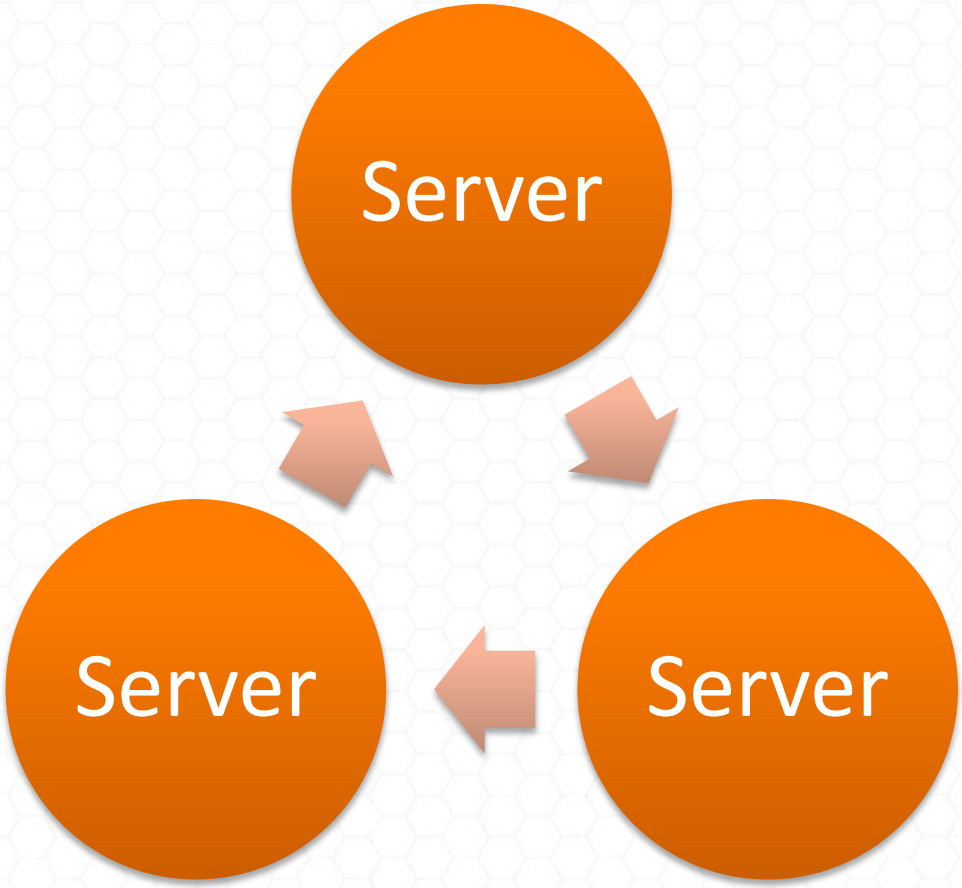

P2P架構

關聯式資料庫的設計模式 - ACID

- ACID 原則
  - Atomicity: 全部執行或全部不執行 (如銀行轉帳)
  - Consistency: 當設定了約束條件，交易始終必須滿足約束條件 (如餘額大於零等約束條件)
  - Isolation: 不同交易並行執行時，不影響互相狀態
  - Durability: 交易完成或認可(Commit)後，狀態的變更是永久的

BASE 原則

- Basically Available
  - 系統大部分屬於可用狀態，允許偶爾的失敗
- Soft State
  - 不要求數據在任意時刻都保持同步
- Eventually Consistency
  - 資料在一定時間內最終會一致

NoSQL 的優點

- 自動水平分散資料 (Sharding)
- 無綱要模型 (Schema Less)
- 極具成本效益(Cost-Effective)

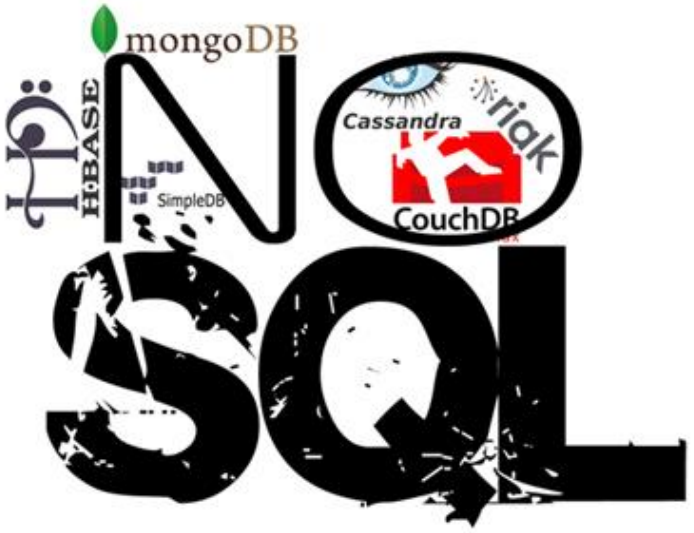

- 適合用在資料一致性與完整性要求較低但量大且快速累積的資料

擴展方便性

- 垂直擴展(Scale Up)
  - 需要幫機器增添CPU, RAM 磁碟空間
  - 擴展時需要啟用備援機器以避免服務中斷
  - 必須使用SAN 等裝置才能分散儲存資料
- 水平擴展 (Scale Out)
  - 只需要加機器到叢集中
  - 可使用標準化量產硬體(Commodity Hardware)
  - 自動負載平衡

無綱要模型 (Schema-Less)

- 使用JSON 等Key-Value 模型表示資料
- 不用顧慮到資料綱要變動時，是否要去修改資料表綱要
- 可以表示概念不同的異質資料 (e.g. 電視與電腦)


```
{
  "data": [
    {
      "id": "10153600155794890",
      "created_time": "2015-09-16T13:12:06+0000",
      "place": {
        "id": "164657790411032",
        "location": {
          "city": "Taipei",
          "country": "Taiwan",
          "latitude": 25.047789030864,
          "longitude": 121.5171581701,
          "street": "中正區北平西路三號二樓"
        },
        "name": "長榮桂冠葡萄酒坊台北車站店"
      }
    },
    {
      "id": "10153472862224890",
      "created_time": "2015-07-26T14:50:22+0000",
      "place": {
        "id": "112196945506136",
        "location": {
          "city": "Sungshan",
          "country": "Taiwan",
          "latitude": 25.050769444444,
          "located_in": "110850655605422",
          "longitude": 121.54993888889,
          "street": "臺北市松山區南京東路4段2號",
          "zip": "10553"
```

極具成本效益 (Cost-Effective)

- 擴展成本
  - 只需要加機器便可完成水平擴展
- 管理成本
  - 管理上較不複雜 (缺乏索引、交易等資料庫複雜設計)
- 硬體成本
  - 可搭載在量產化硬體機器上

A history of databases in No-tation

1970: NoSQL = We have no SQL

1980: NoSQL = Know SQL

2000: NoSQL = No SQL!

2005: NoSQL = Not only SQL

2013: NoSQL = No, SQL!

(R)DB(MS)

NoSQL 應與關聯式資料庫機制並行

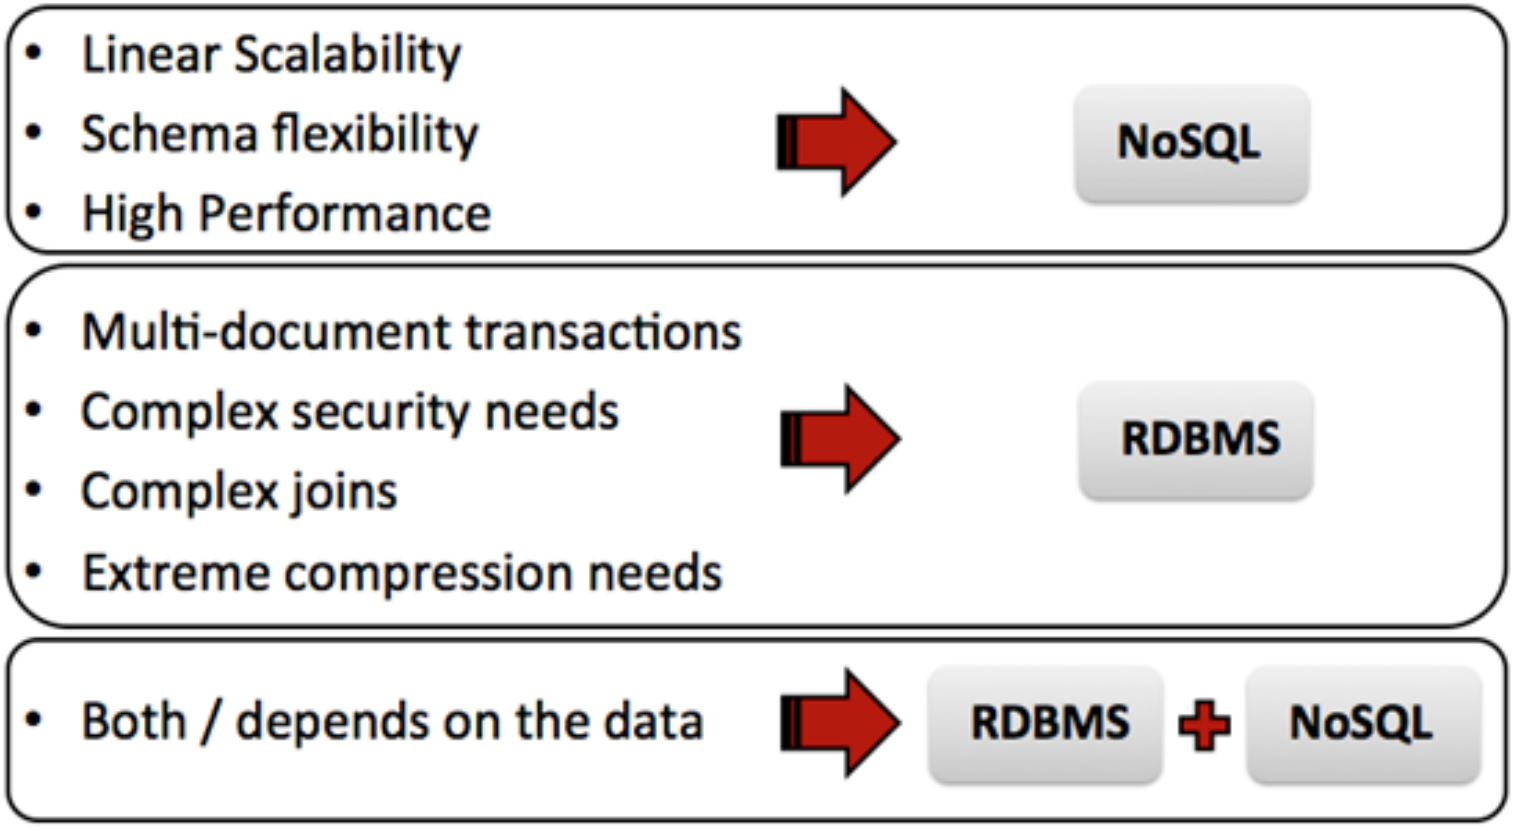

NoSQL在不同公司的應用情境

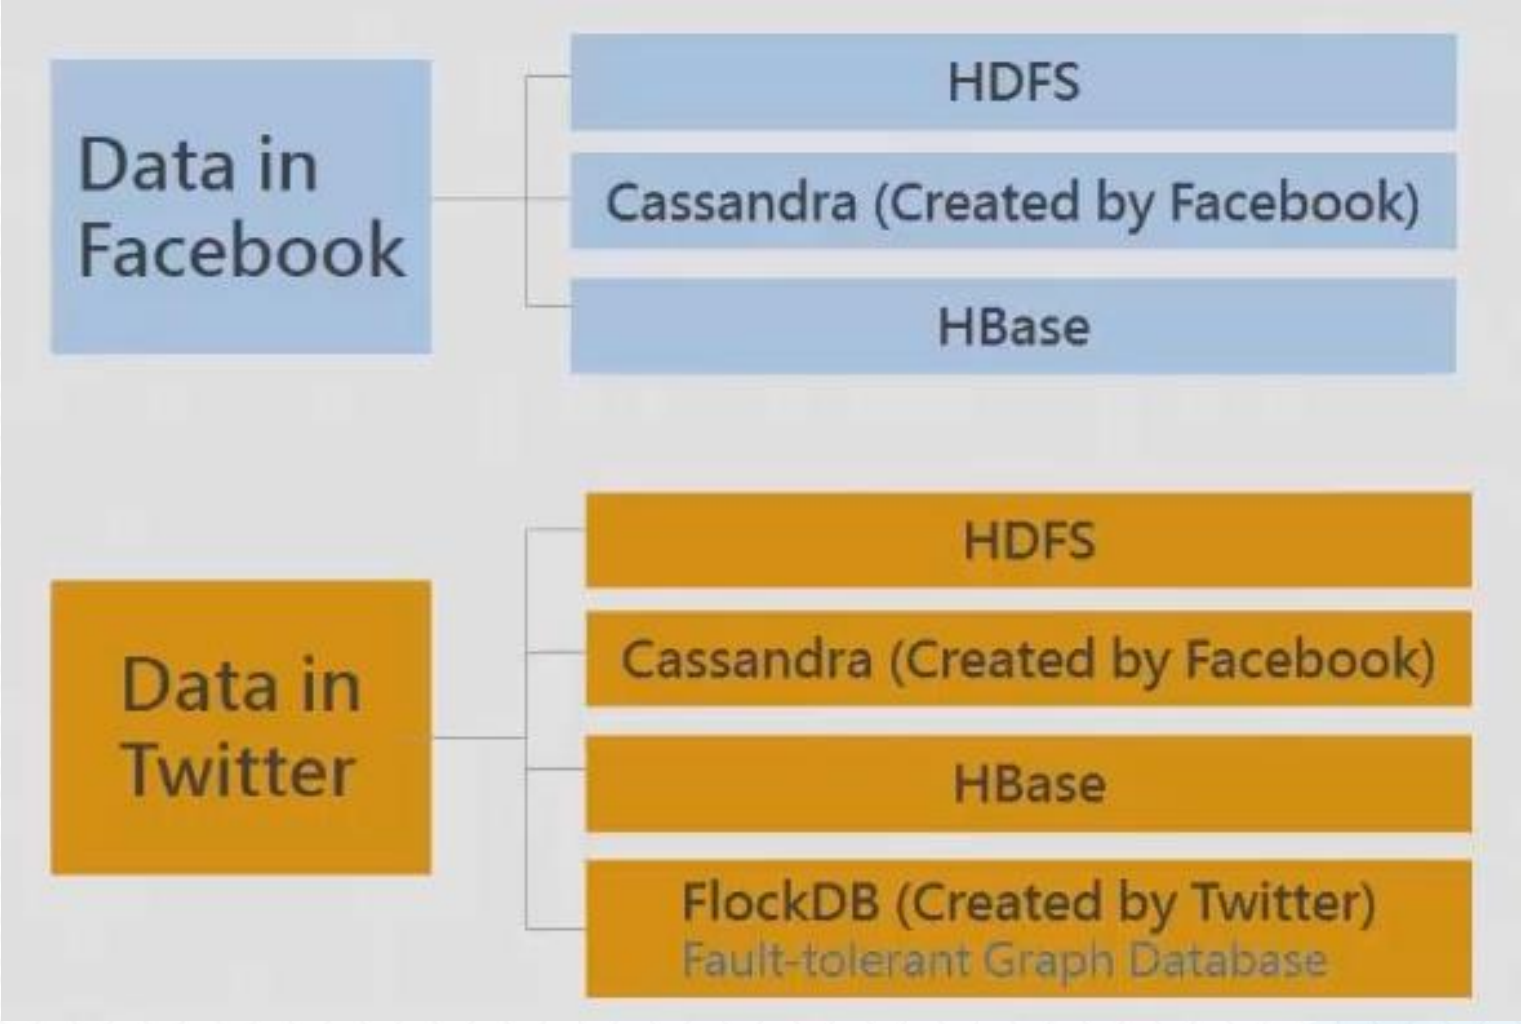

NoSQL的種類

NoSQL 種類

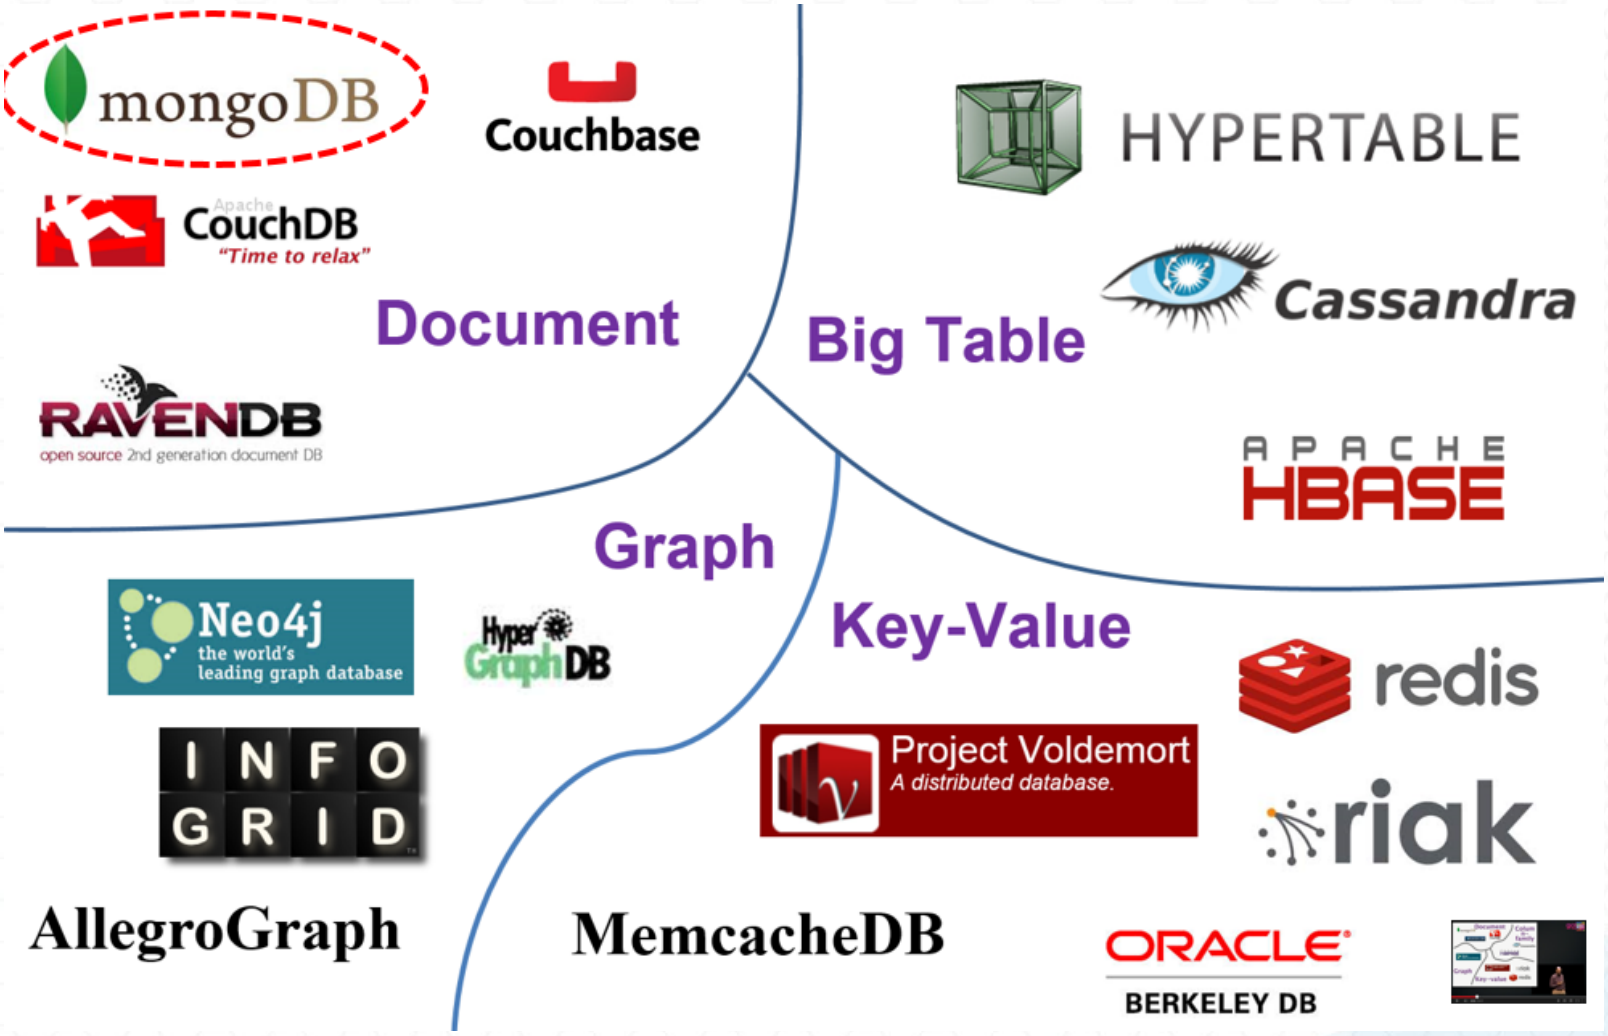
mongoDB
Couchbase
Apache CouchDB "Time to relax"
Document
RAVENDB open source 2nd generation document DB
HYPERTABLE
Cassandra
Big Table
APACHE HBASE
Graph
Neo4j the world's leading graph database
HyperGraphDB
INFO GRID
AllegroGraph
Key-Value
redis
Project Voldemort A distributed database.
riak
MemcacheDB
ORACLE BERKELEY DB

Facebook 的儲存技術

- Facebook 用關聯式資料庫與NoSQL儲存資料
  - MySQL：儲存會員資料
  - Memcached: 資料庫快取
  - Cassandra:儲存站內信箱資訊
  - HBase：訊息的儲存，建立訊息的反向索引

NoSQL 種類

- Key/Value型 – 以Key/Value存放資料
  - Memcached
  - Amazon DynamoDB
- Column-based型 – 列式資料庫
  - BigTable
  - Cassandra
- Document-based –以XML、JSON等文件形式保存資料
  - MongoDB，
  - CouchDB

Key-value

Key	Value
“India”	{“B-25, Sector-58, Noida, India – 201301″
“Romania”	{“IMPS Moara Business Center, Buftea No. 1, Cluj-Napoca, 400606″,City Business Center, Coriolan Brediceanu No. 10, Building B, Timisoara, 300011″}
“US”	{“3975 Fair Ridge Drive. Suite 200 South, Fairfax, VA 22033″}

key-value 資料庫

- 適合
  - 儲存session
  - 使用者檔案與喜好設定
  - 購物車資料
- 不適合
  - 資料間關係
  - 多動作交易
  - 由資料做查詢
  - 一組的動作

電商的購物車資料

Redis

- **RE**mote **DI**ctionary **S**erver(Redis)
- 將資料存放在記憶體中
  - 如同Memcached

- 以Key-Value作為儲存形態
  - 一個Key值所儲存的Value可以是字串(strings), 雜湊(hashes), 清單(lists), 資料集(sets)與可排序資料集(sorted sets)。

Redis v.s. Memcached

- 資料類型
  - Redis支援更豐富的資料類型
- 物件大小
  - Redis支援的物件大小最大支援1GB，而Memcached僅為1MB
- 分片(Sharding)
  - 可以將資料離散地存儲在不同的物理機器上
- 持久化
  - Redis能夠將記憶體中的資料持久化到磁片，而Memcached則只能用做功能有限的緩存中介

Column-based NoSQL 資料庫

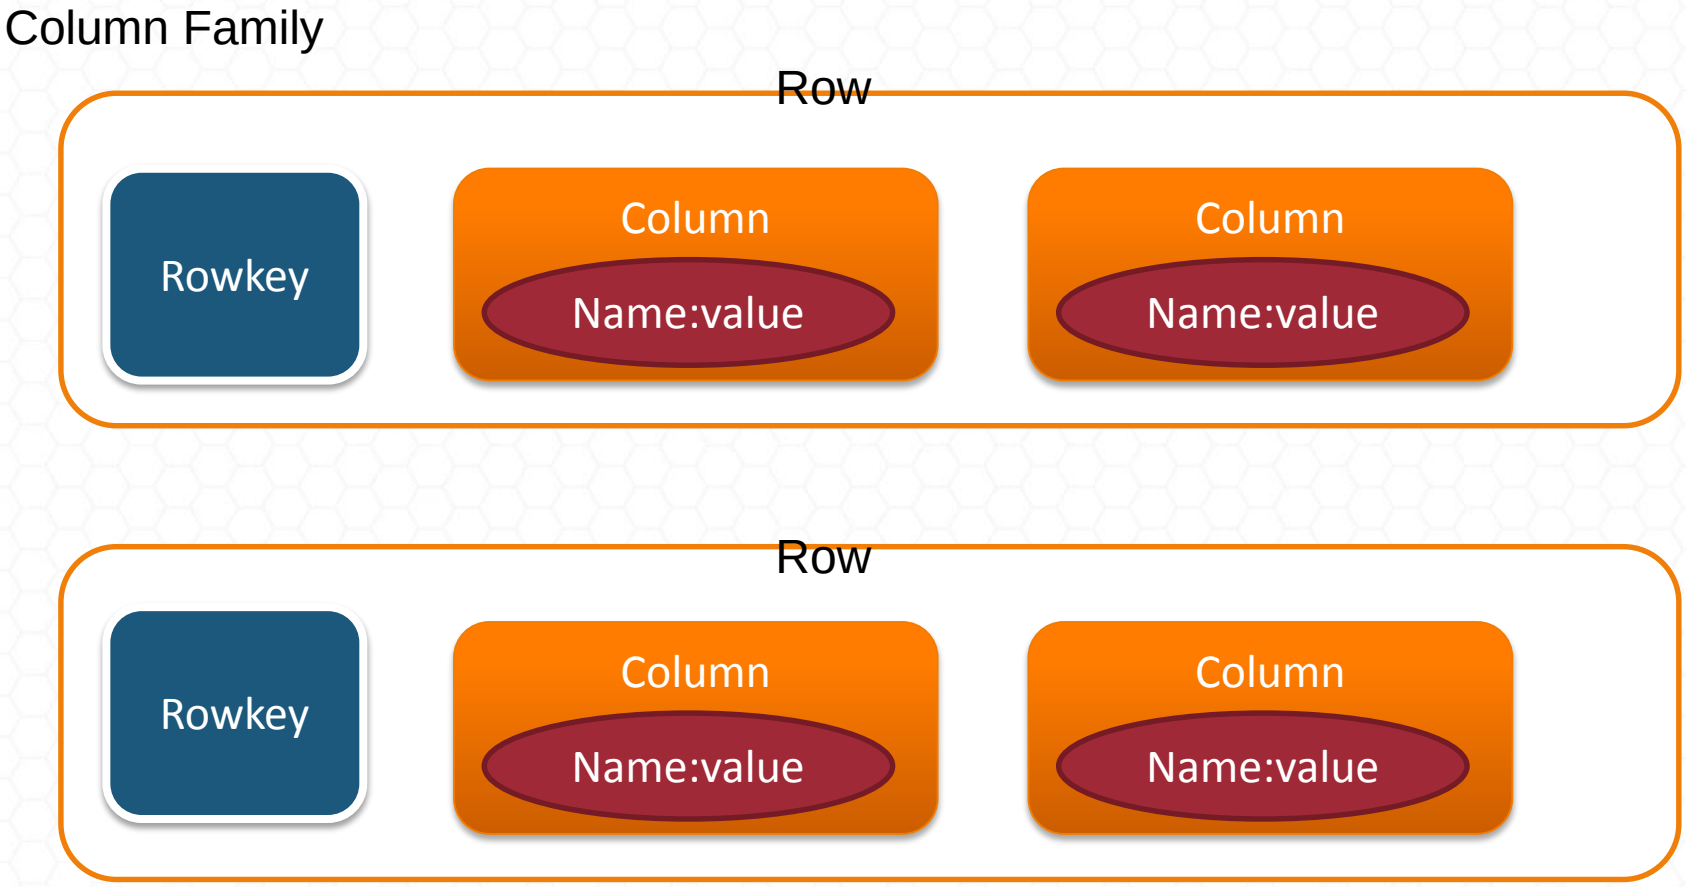

Schema-Less 資料儲存概念

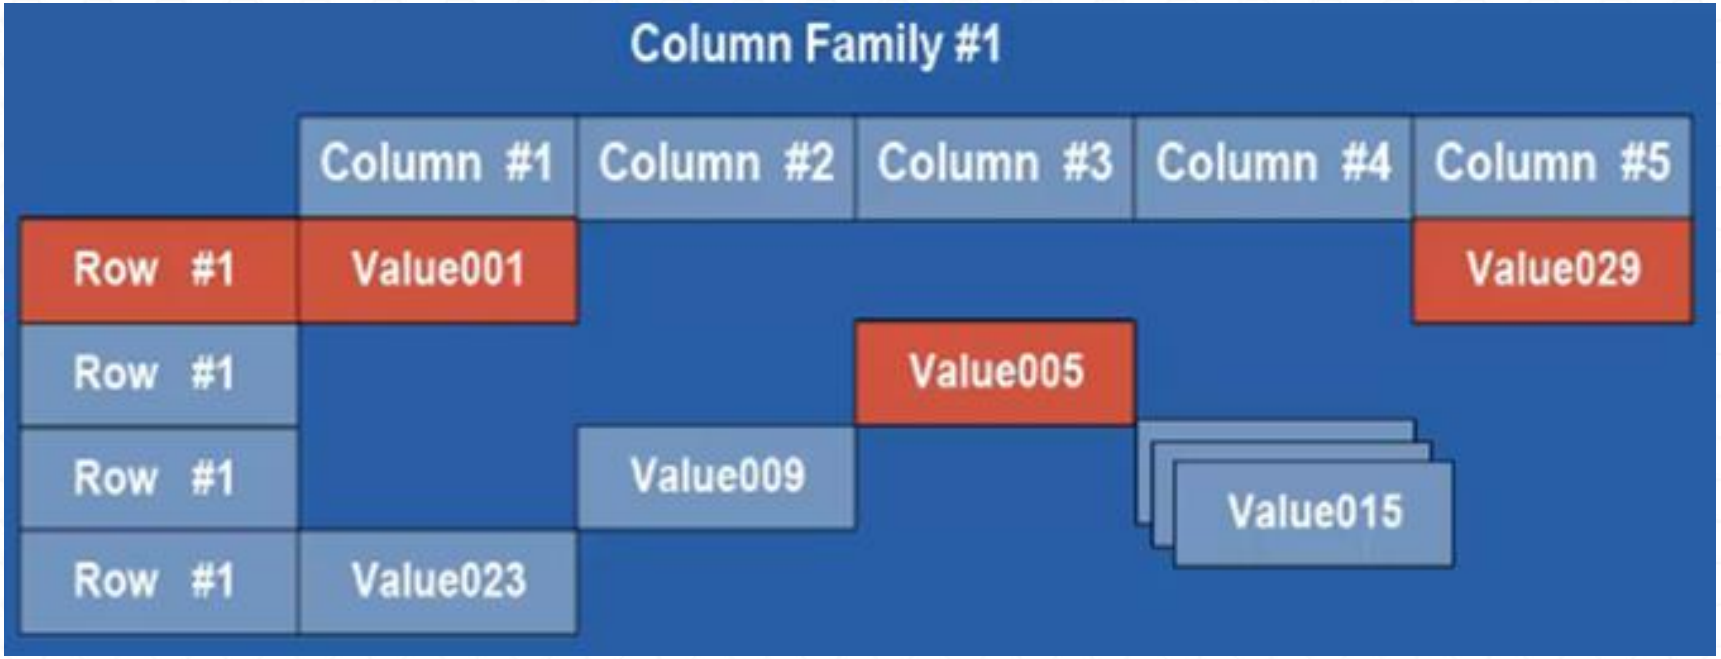

Column-based NoSQL 資料庫

```
{
  3PillarNoida: {
    address: { city: Noida,   pincode: 201301},
    details: { strength: 250, projects: 20}
  },
  3PillarCluj: {
    address: { city: Cluj, pincode: 400606},
    details: { strength: 200, projects: 15}
  },
  3PillarTimisoara: {
    address: { city: Timisoara, pincode: 300011},
    details: { strength: 150,  projects: 10}
  },
  3PillarFairfax : {
    address: { city: Fairfax, pincode: VA 22033},
    details: { strength: 100, projects: 5}
  }
}
```

City	Pincode	Strength	Project
Noida	201301	250	20
Cluj	400606	200	15
Timisoara	300011	150	10
Fairfax	VA 22033	100	5

- 3PillarNoida, 3PillarCluj, 3PillarTimisoara , 3PillarFairfax 為資料鍵 (Key) 相當於表格列

- address, details 為 column families
- address 包含欄位 city, pincode
- details 包含欄位strength, projects

Column-based 資料庫

- 適合
  - 事件歷史紀錄
  - 內容平台
  - 計數器
  - 限時間使用的資料
- 不適合
  - 需要ACID 的系統

Facebook 訊息資料

Cassandra

- 由Facebook開發
- 集Google BigTable的資料模型與Amazon Dynamo的完全分散式的架構於一身
- 列被組織成為列族（Column Family），在資料庫中增加一列非常方便
- 基於P2P架構，與傳統的基於分片的資料庫集群相比，Cassandra可以幾乎無縫地加入或刪除節點

Cassandra 特點

- 模式靈活
  - 使用Cassandra，像文檔存儲，你不必提前解決記錄中的欄位。你可以在系統運行時隨意的添加或移除欄位
- 真正的可擴展性
  - 當需要替集群添加更多容量，可以指向另一台電腦。不必重啟任何機器，改變應用查詢，或遷移任何資料
- 多資料中心識別
  - 可以調整你的節點佈局來避免某一個資料中心發生意外

Hbase

- 分散式
- 多維度
- 高效能
- 存儲系統
- High- Availability
- Column- Oriented

存儲大量的行、列及多版本資料，並能分散到數以萬計的機器中

建立推薦系統

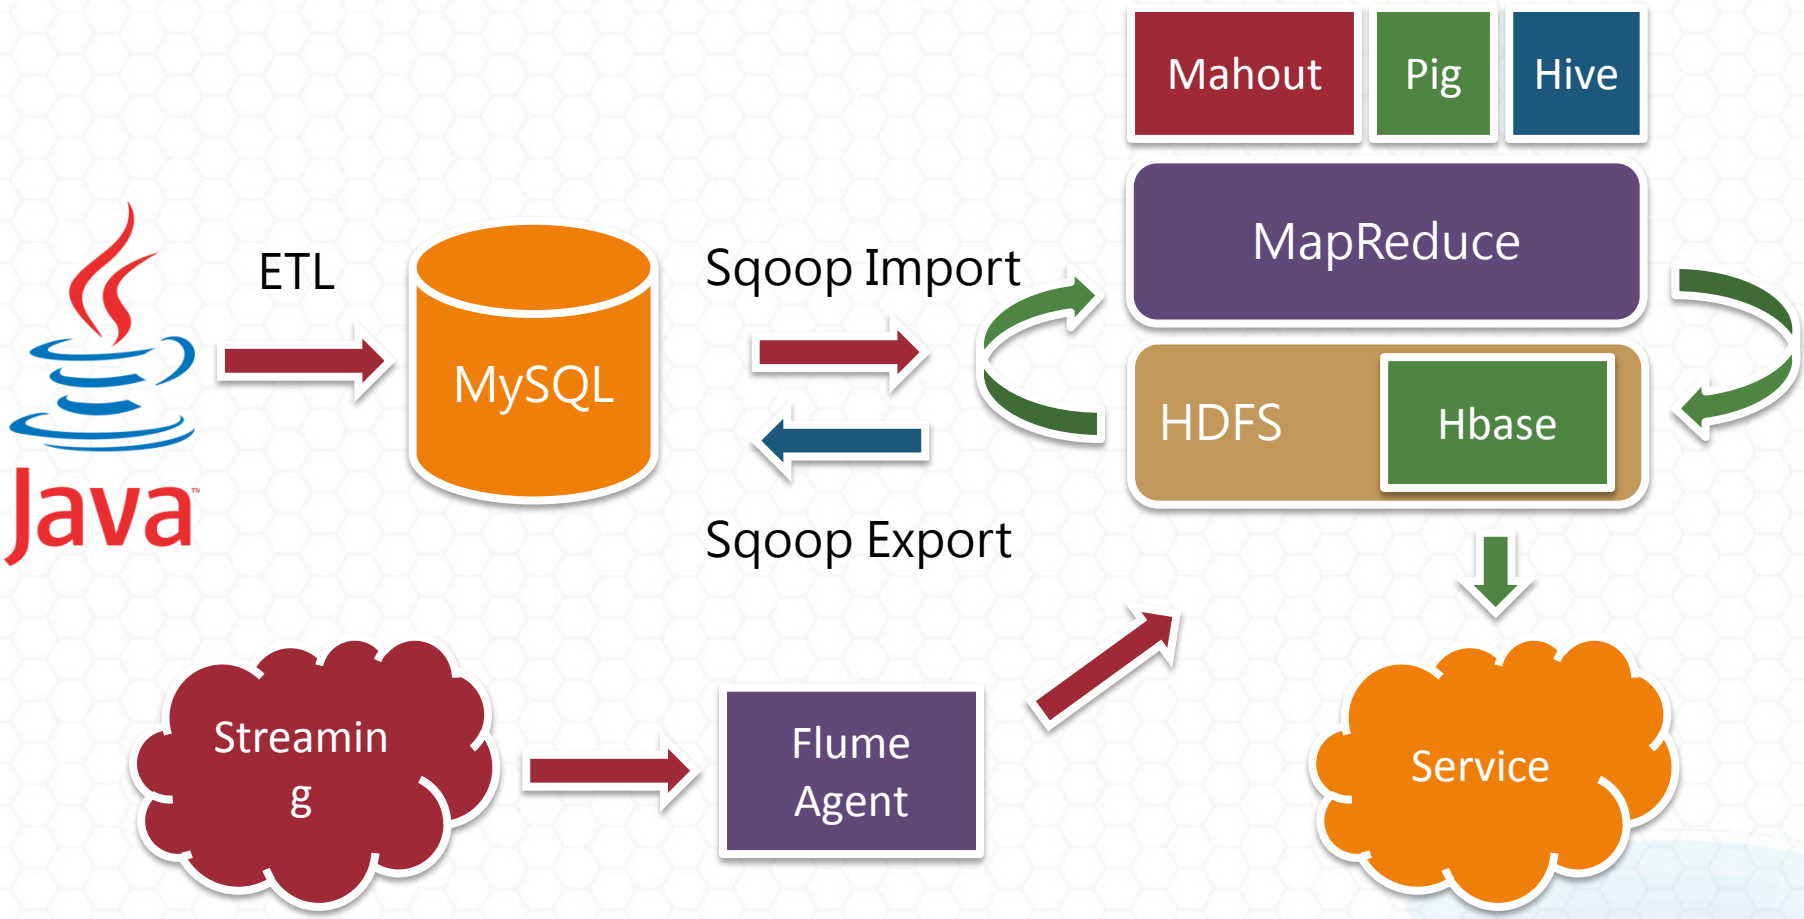
Mahout
Pig
Hive
MapReduce
HDFS
Hbase
ETL
MySQL
Sqoop Import
Sqoop Export
Java
Streamin
g
Flume
Agent
Service

Document Database

- 將資料以”檔案”(XML, JSON)形式儲存
- 可以透過半結構化語法存取內容

```
{officeName:”3Pillar Noida”,
{Street: “B-25, City:”Noida”, State:”UP”, Pincode:”201301”}
}
{officeName:”3Pillar Timisoara”,
{Boulevard:”Coriolan Brediceanu No. 10”, Block:”B, Ist Floor”, City: “Timisoara”, Pinc
}
{officeName:”3Pillar Cluj”,
{Latitude:”40.748328”, Longitude:”-73.985560”}
}
```

Document Database

- 適合
  - 事件歷史紀錄
  - 內容平台
  - 電子商務應用程式
  - 網路點擊資料
- 不適合
  - 不同動作的複雜交易
  - 不同結構的查詢

使用者點擊資料蒐集

MongoDB

- 使用BSON的格式來存取資料-
  - Bson = binary json
  - bson也支援較Json 更多的data type
- GridFS
  - 存儲資料的chunks與metadata
  - 當存取資料時就可以快速的到達資料存放的位置
- 支援分散式資料庫
  - 可以把資料庫放在不同主機
  - 自動分散資料負載 (Sharding, Rebalancing)

GraphDB

- 儲存、搜尋物品與人際關係
- 每個人可視為一個點，每條線視為之間的關係

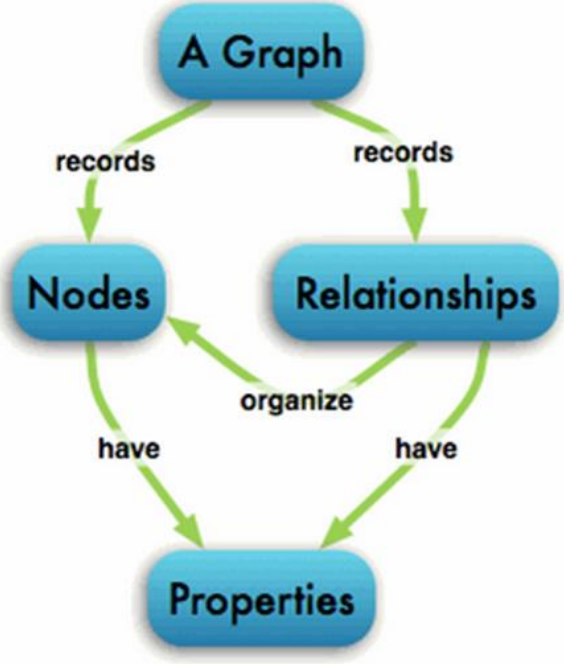

GraphDB

- 適合
  - 連結的資料
  - LBS 服務
  - 推薦引擎
- 不適合
  - 大量log 資料

儲存人與人之間的關係

Neo4j

- 圖形資料庫系統 (Graph Database)
- 主要使用 Java 程式語言撰寫
- 可以針對複雜的「關係」(Relationship) 進行設計與分析
- 解決傳統關聯式資料庫難以處理的關係搜尋

Hbase 簡介

HBase 歷史

- Hbase 1.0 於 2015 年發表

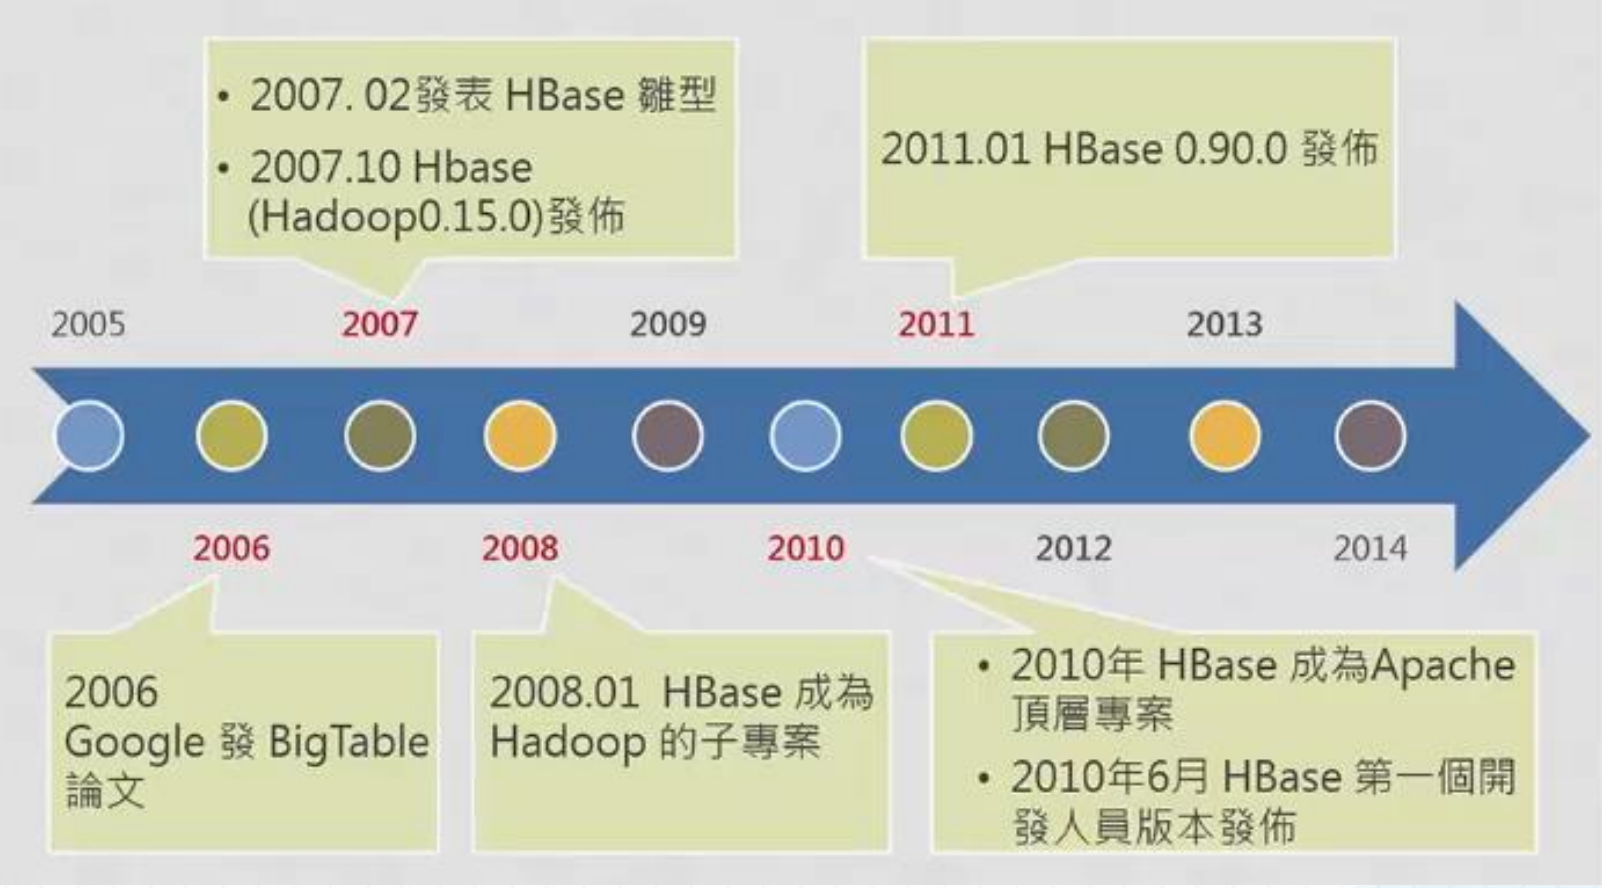

Hbase

- 根據Google 2006年 BigTable 論文實作
- 分散式、多維度、高效能的存儲系統
- 存數十億列、數百萬欄
- High- Availability
- Column- Oriented

存儲大量的行、列及多版本資料，並能分散到數以萬計的機器中

Hbase 與RDBMS 的差異

- 並非關聯式資料庫
  - 沒有Join, Query engine, 類型, SQL
  - 有支援Transaction 跟 Secondary Index – 發展中
- 並非傳統資料庫的替代品
- 沒有Schema (Anti-Schema)的概念
  - 資料是非正規化的
  - 超大型Excel

HBase 架構

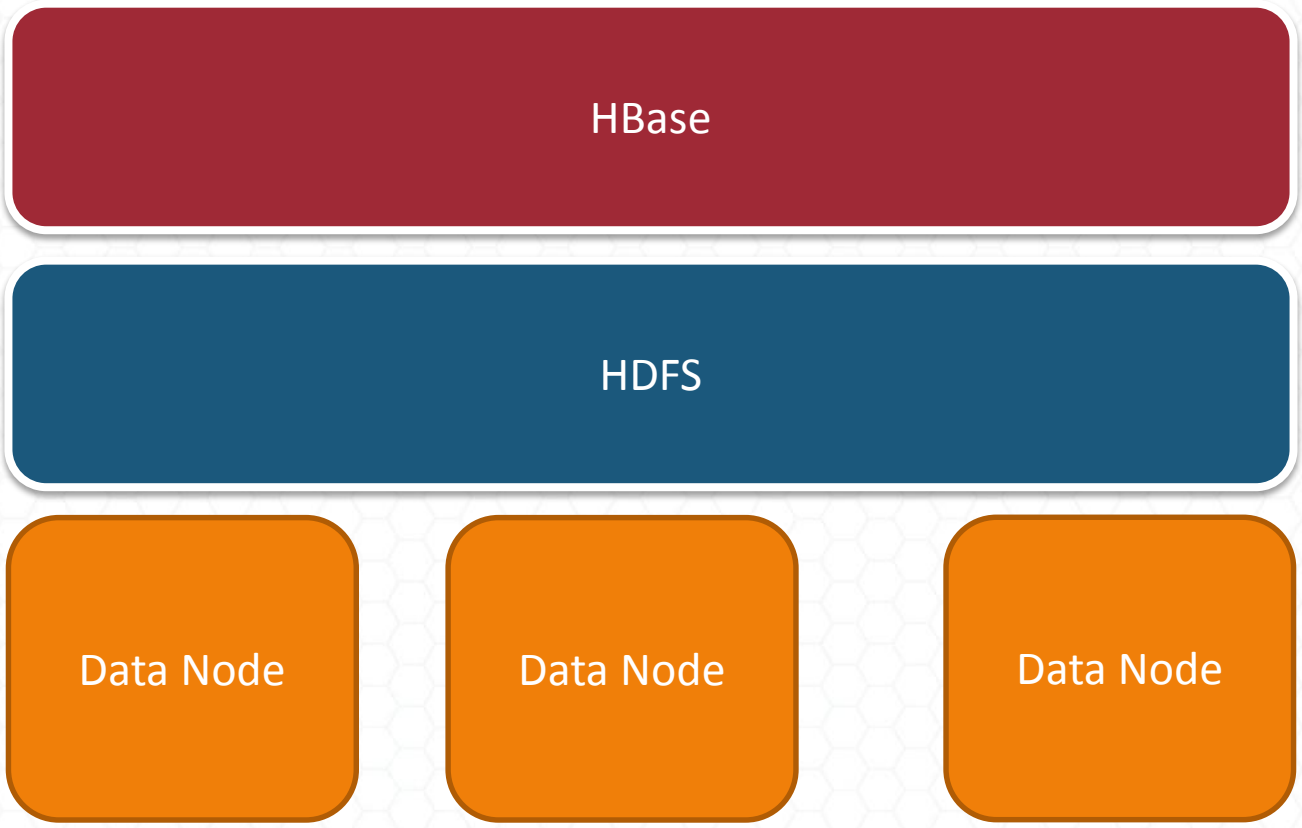

資料存放模式

資料是根據字典順序擺放

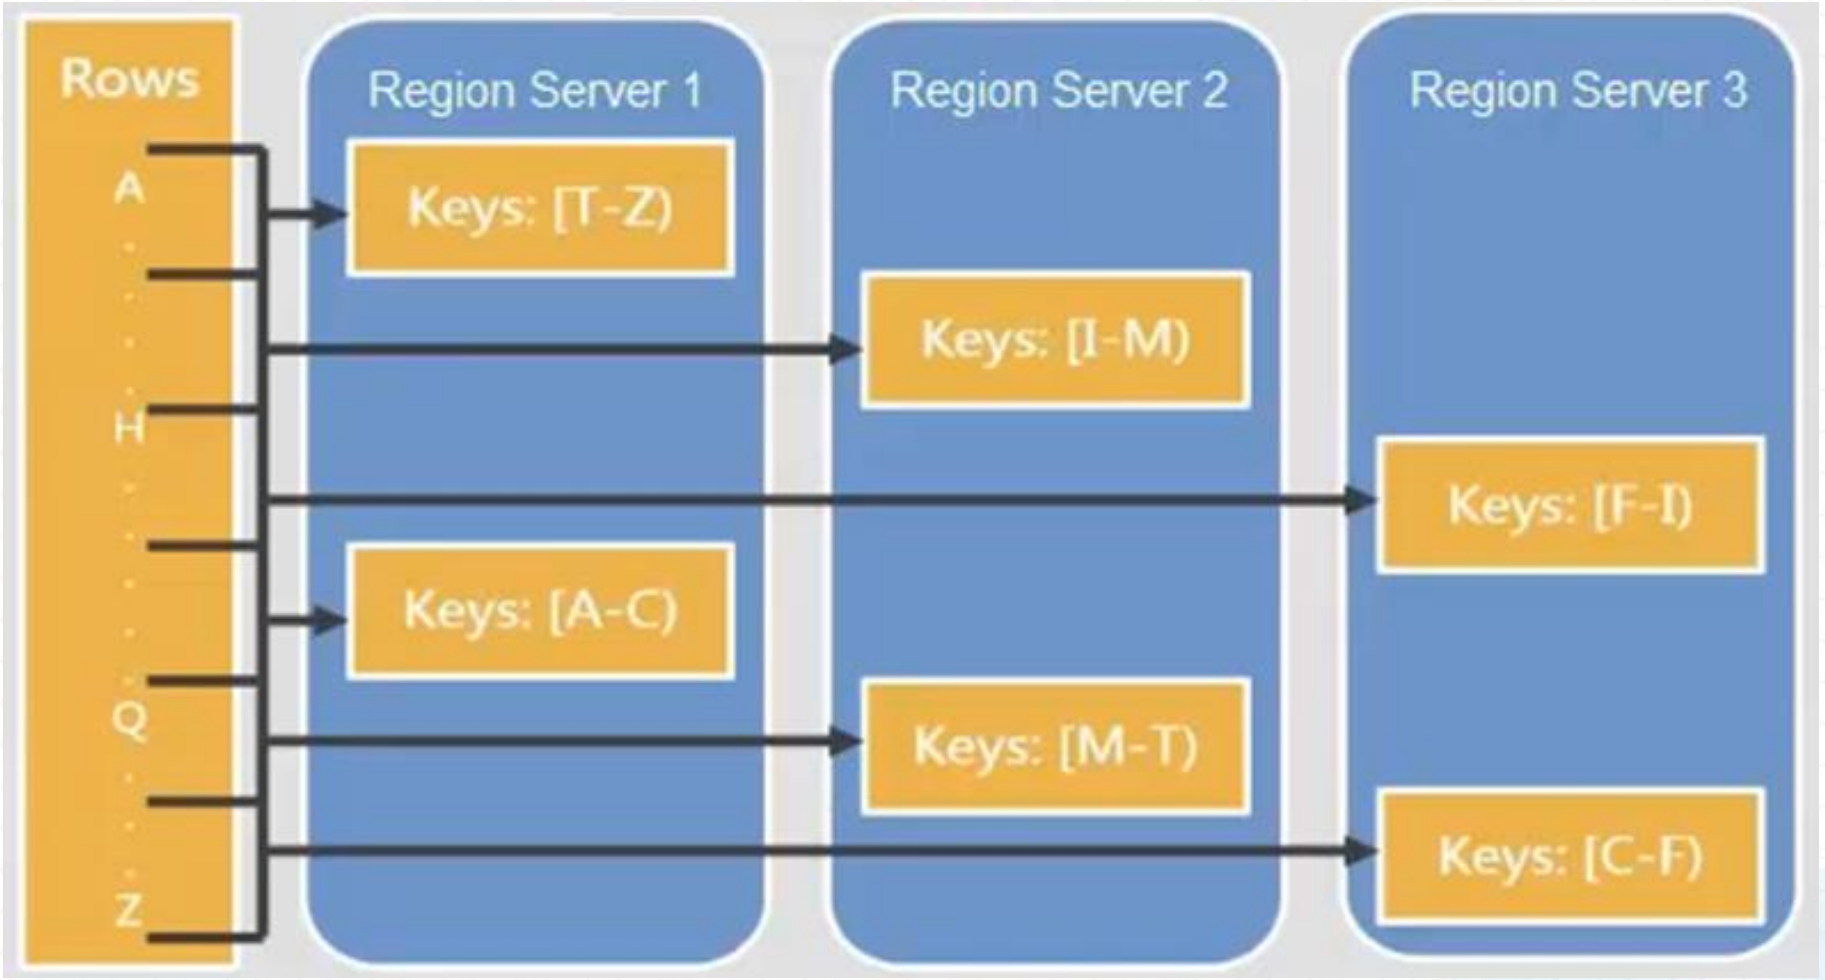

Hbase 架構

- 表格是由Regions 所組成
- Region 是由startKey 與endKey 所定義的
  - 空白表格:
    - Table, NULL, NULL
  - Two-region table
    - (Table, NULL, “streamy”) and (Table, “Streamy”, NULL)
- 每個Region是由多個HDFS 檔案與Block所組成，同時存在於多台node 上

Table, Region, Region Server

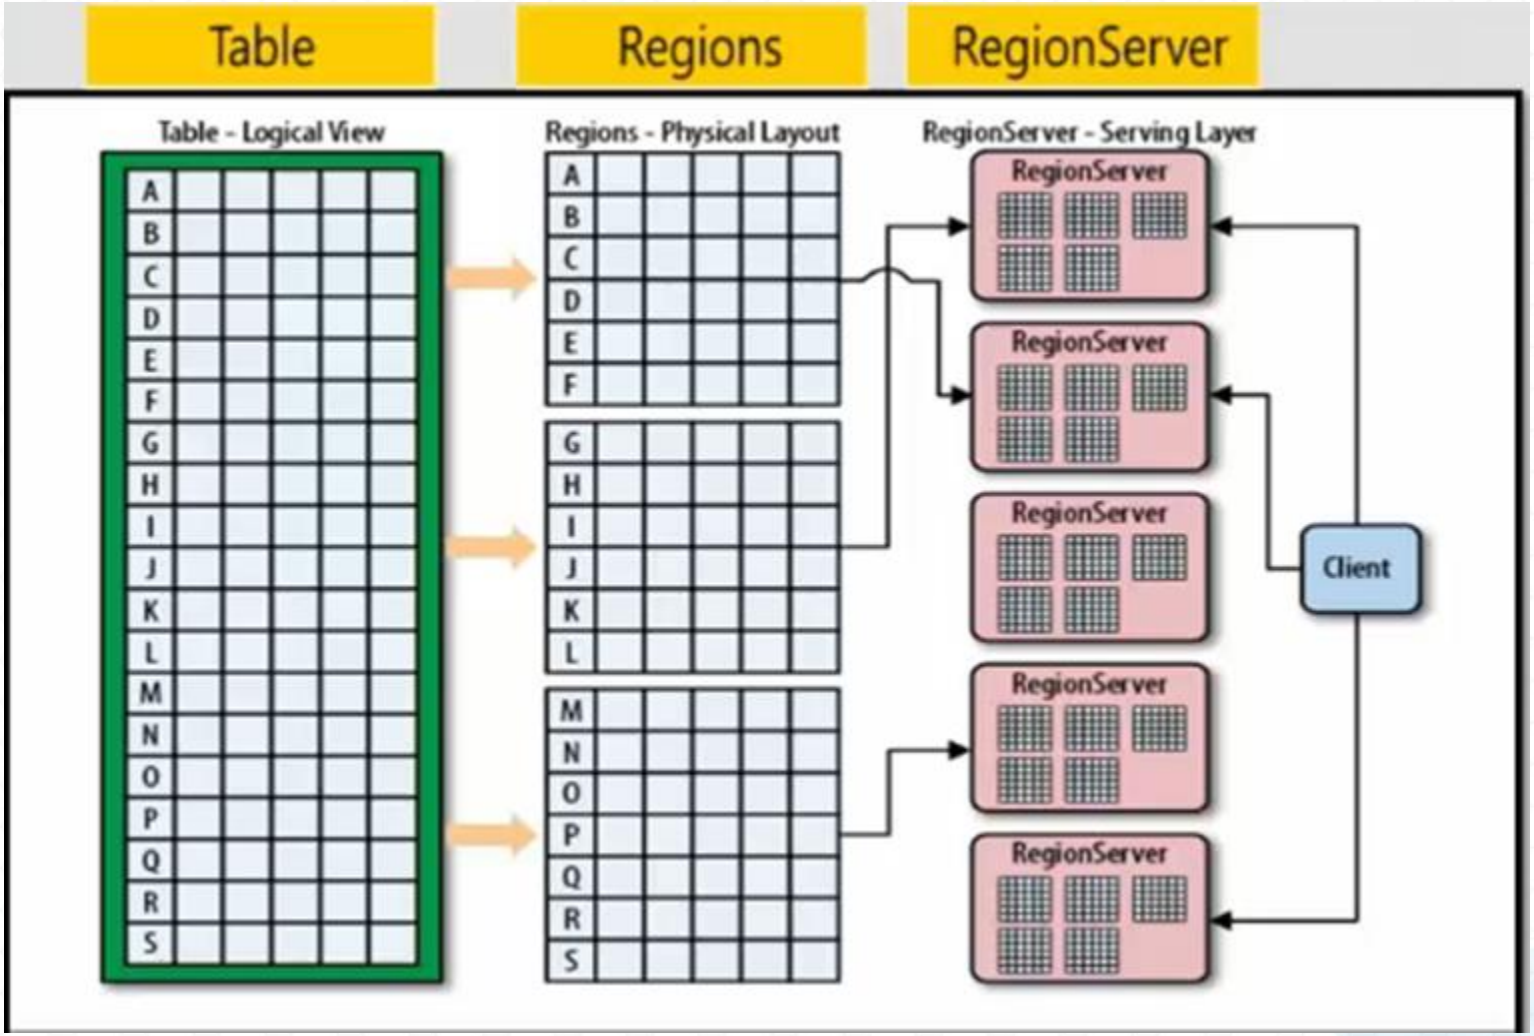

一個Region Server 所存放的Region 可能來自不同的Table
由Master 決定哪台Region Server 擺放哪些Regions

HBase 硬體與元件

硬體配置

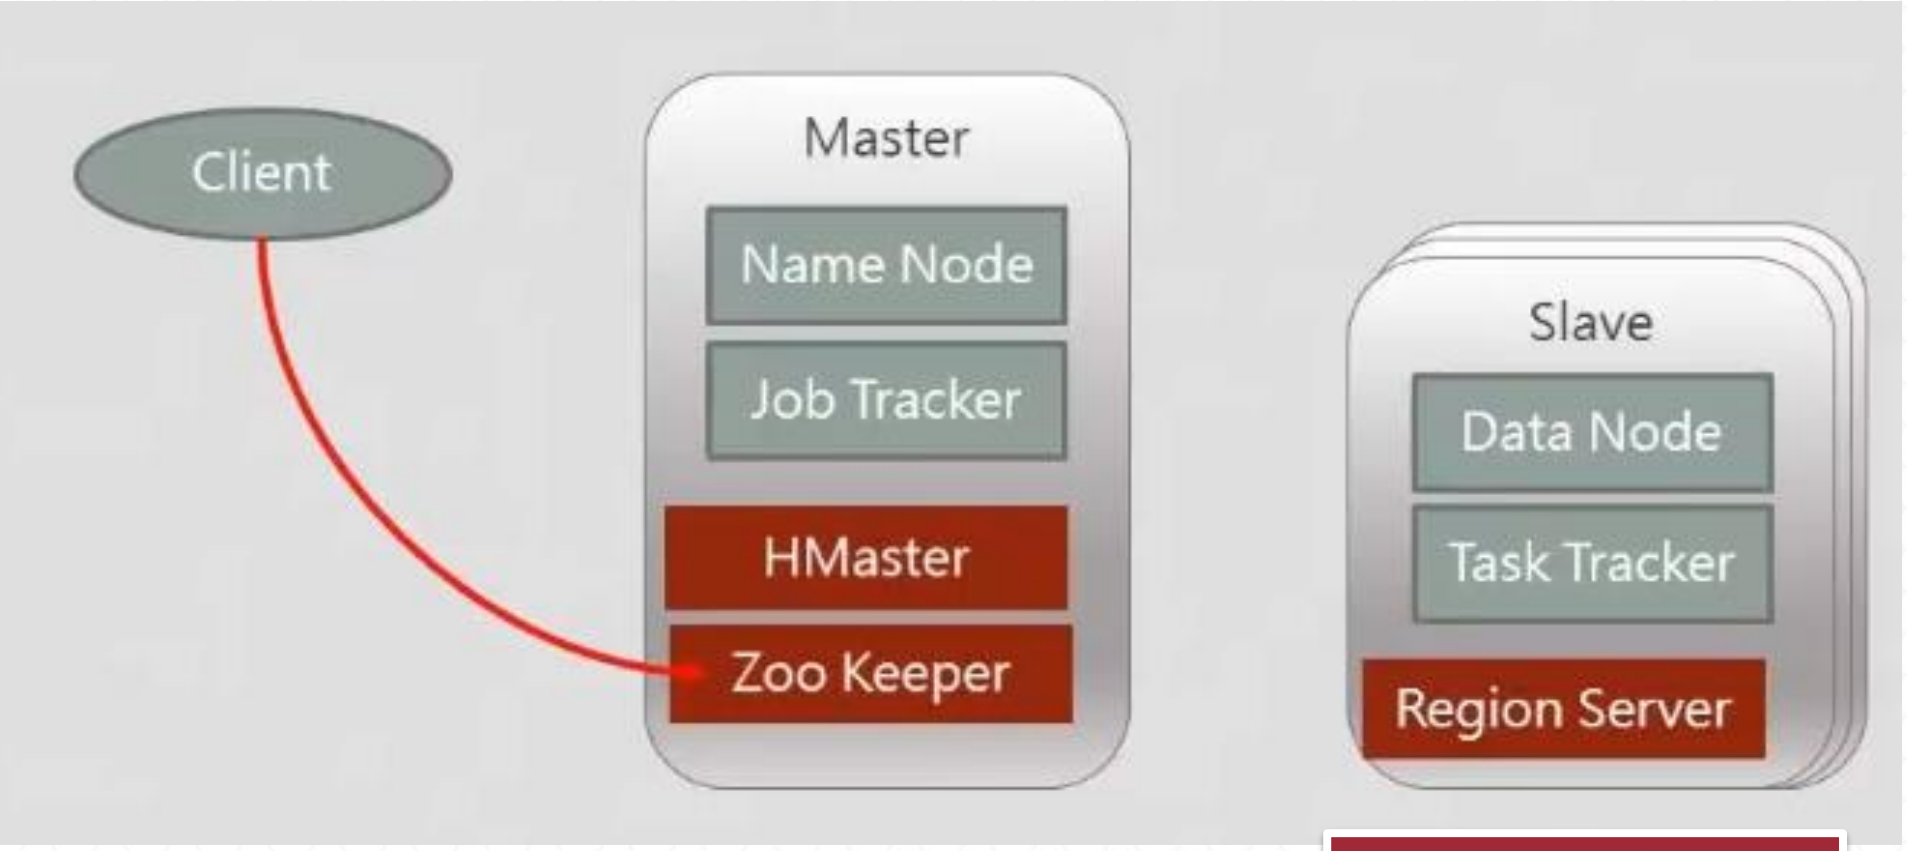

Region Server 存放資料

HBase - HMaster

- 分配 Region Server 管理的 Region
- 做為 Region Server 的 Load Balancer
- 偵測故障的Region Server, 並將其Region 重新分配到其他Region Server
  - 重新分配時系統會暫時Hang 住
- 更新表格的Table Schema

Region Server

- 運行在 Data Node 上
- 維護Master 分配的 Region，處理對Region 的 IO 需求
- 切割在運行過程中儲存空間超過門檻值的Region
  - 會警示Master 是否存放Region 過大，請示Master 裁切資料

Zookeeper

- Google 的Message Queue (Chubby)
  - 分散式系統協調機制
- 確保在任何時候都只有一個Master
  - 使用投票機制
- 儲存Region 的 Mapping 機制
  - 可跳過Master 存取到Region Server 的內容
- 儲存Hbase 的 Schema, 包含Table 以及Table 有哪些 Column Family
- 監控Region Server 的狀況，告知Master 關於Region Server 的啟動與斷線
- 所有的服務及HeartBeat 都交由Zookeeper 管理與協調

小型叢集佈署

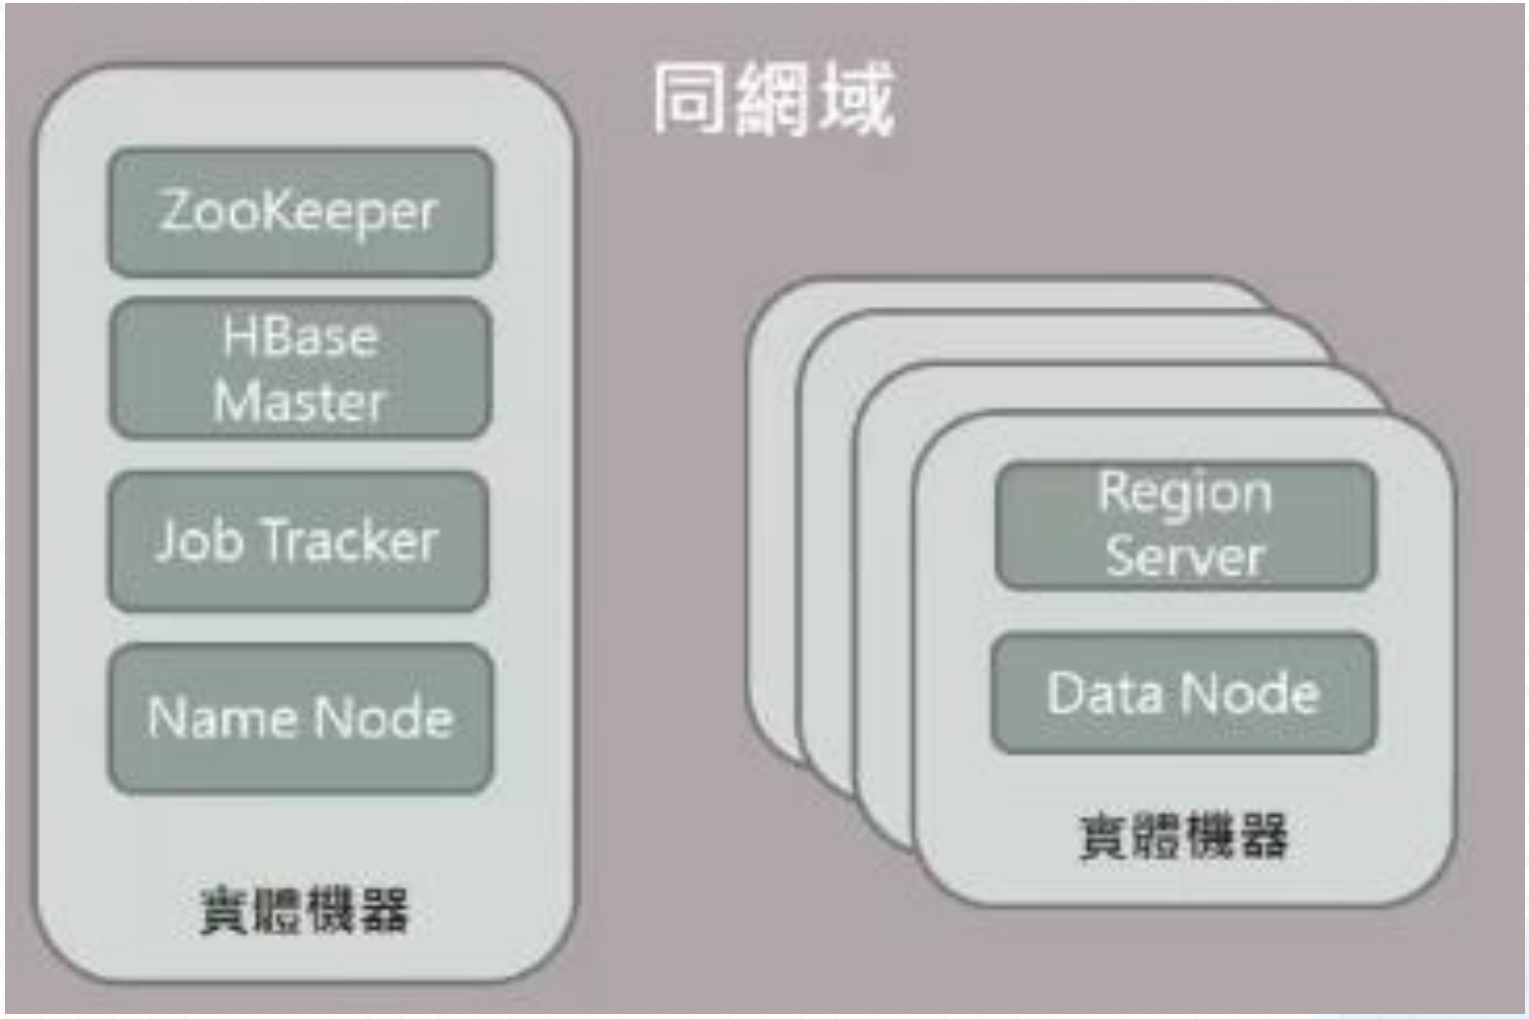
同網域
ZooKeeper
HBase Master
Job Tracker
Name Node
實體機器
Region Server
Data Node
實體機器

叢集配置

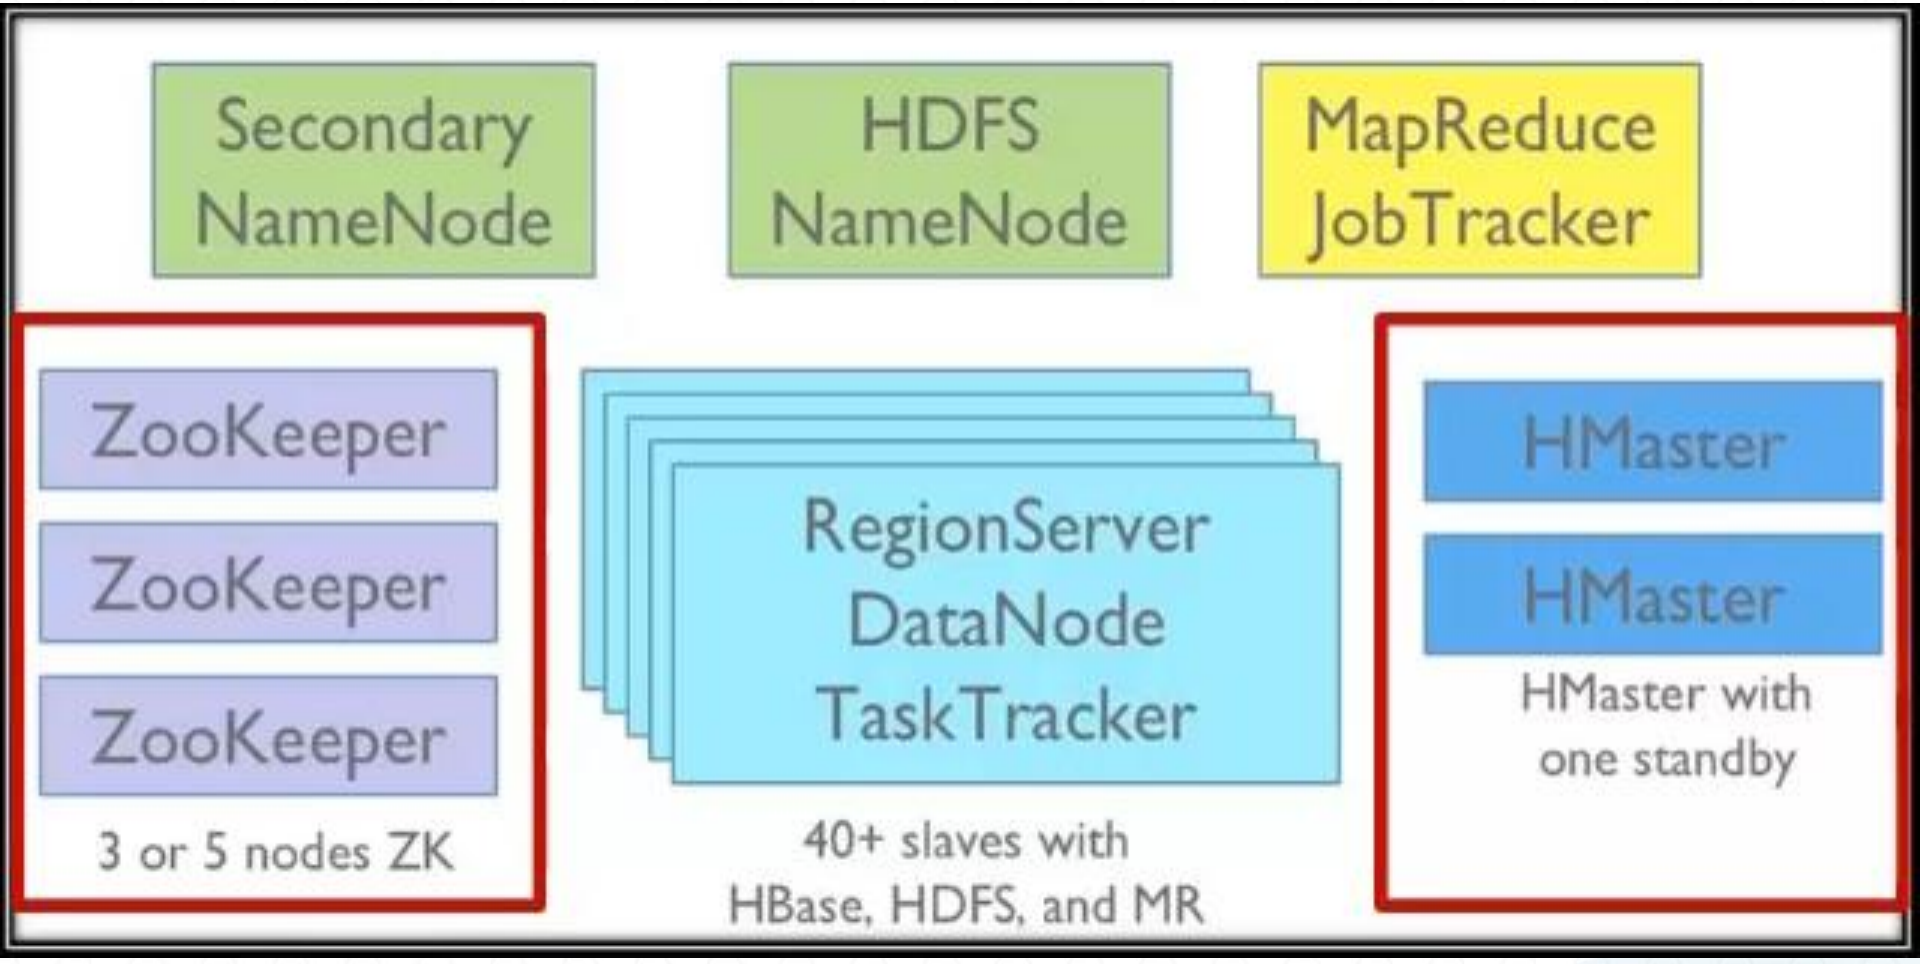
Secondary NameNode
HDFS NameNode
MapReduce JobTracker
ZooKeeper
ZooKeeper
ZooKeeper
3 or 5 nodes ZK
RegionServer
DataNode
TaskTracker
40+ slaves with HBase, HDFS, and MR
HMaster
HMaster
HMaster with one standby

資料讀取

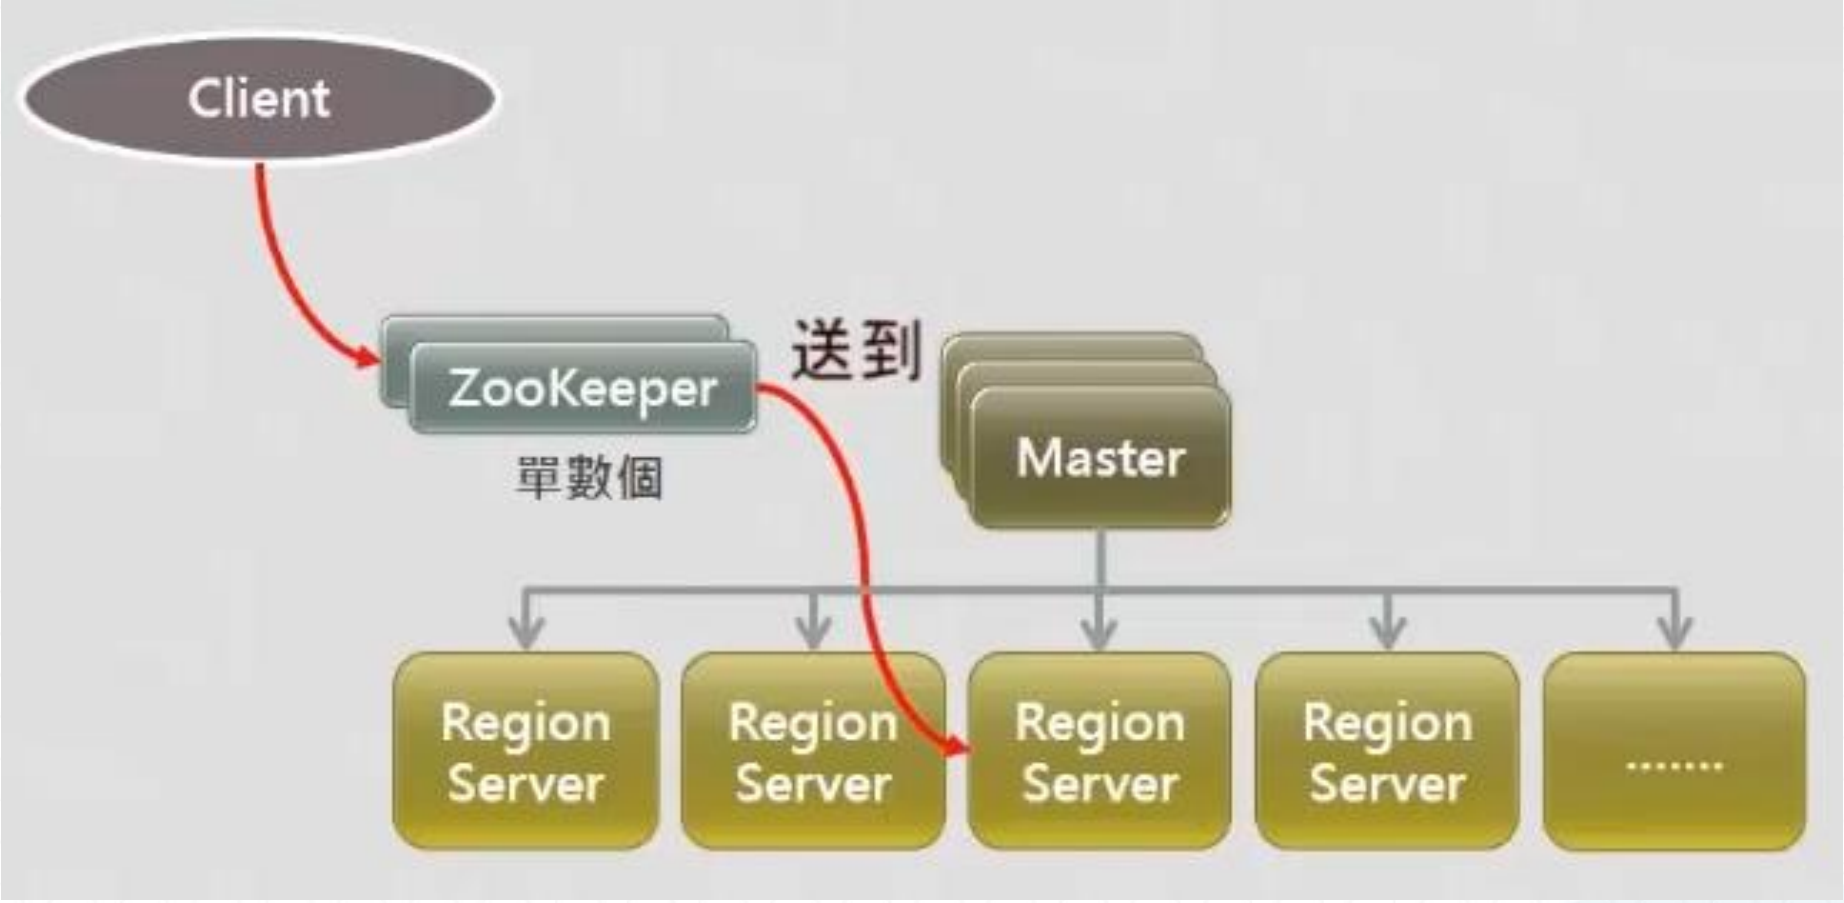
Client
ZooKeeper
單數個
送到
Master
Region Server
Region Server
Region Server
Region Server
.....

資料寫入

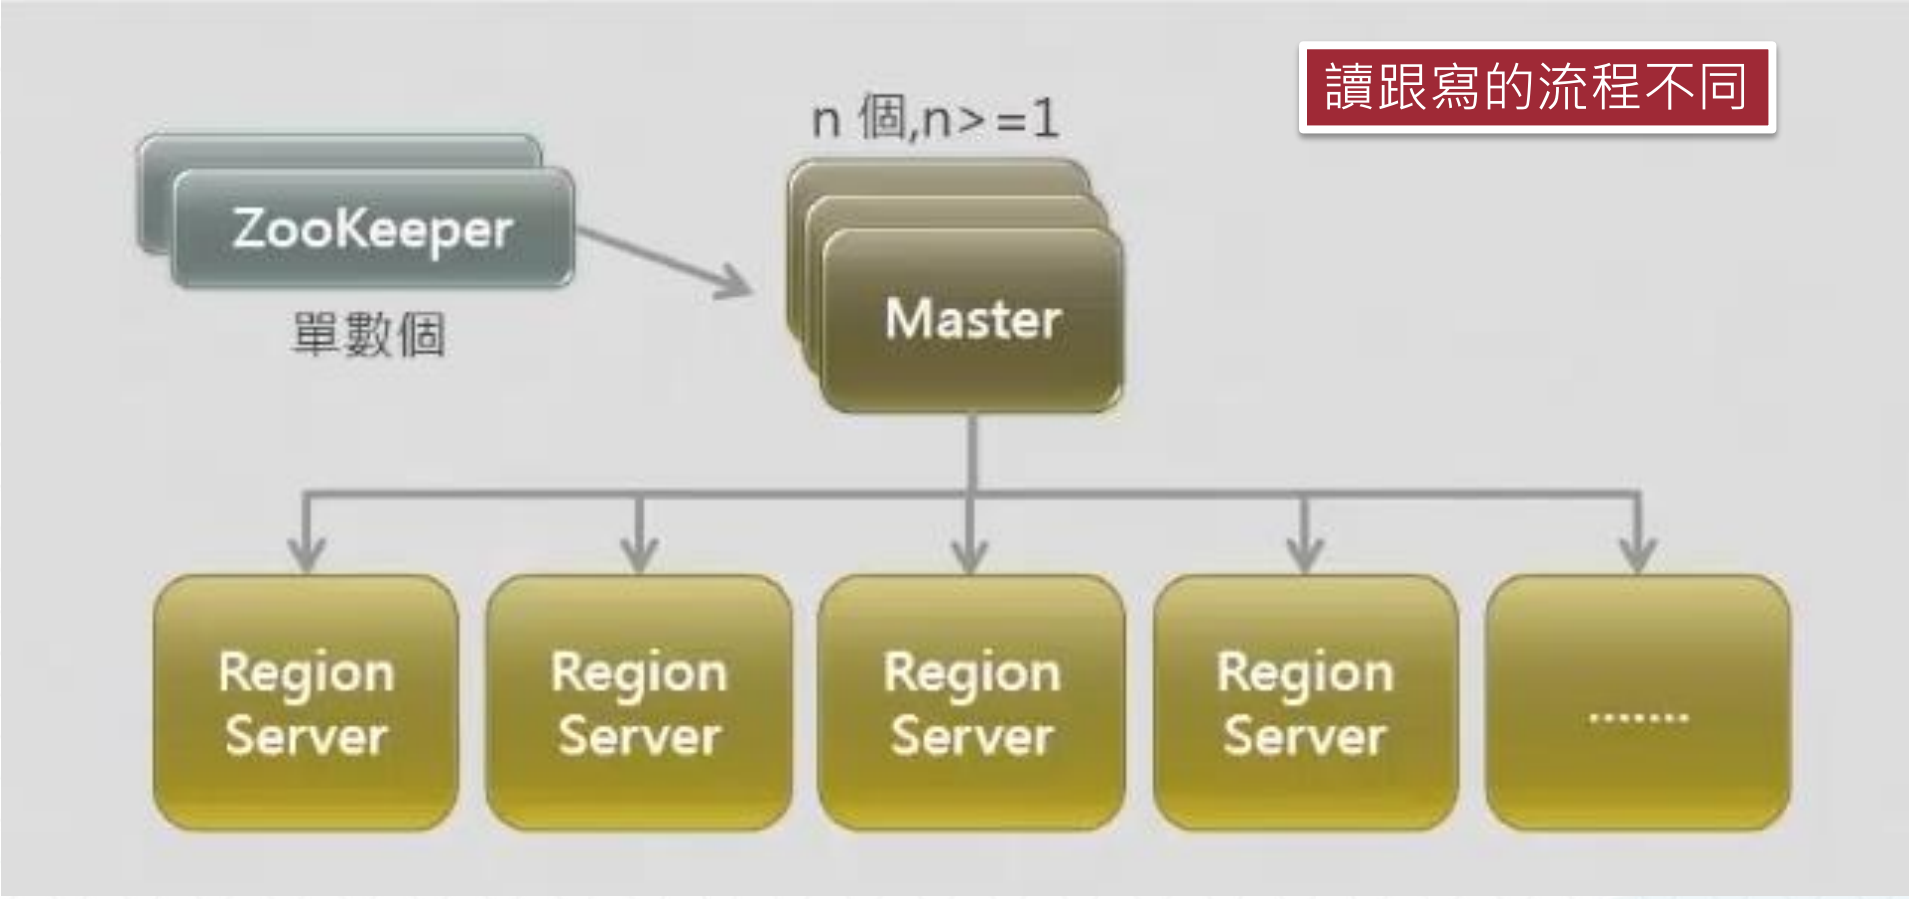
讀跟寫的流程不同
n 個,n>=1
ZooKeeper
單數個
Master
Region Server
Region Server
Region Server
Region Server
.....

HBase 資料存儲

Hbase 架構

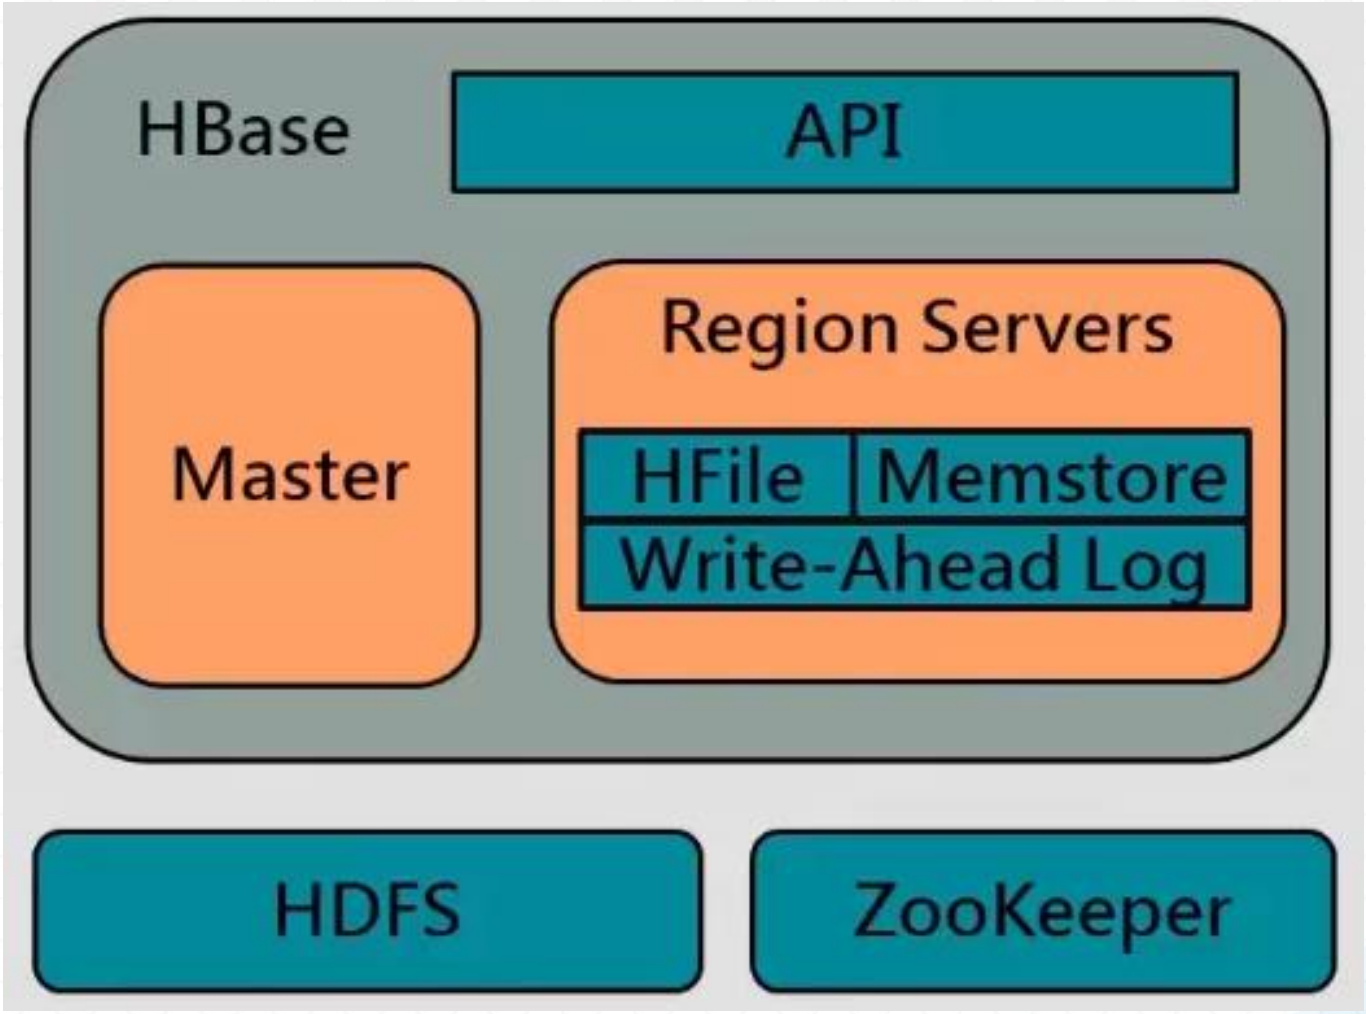
HBase
API
Master
Region Servers
HFile
Memstore
Write-Ahead Log
HDFS
ZooKeeper

Hbase 架構

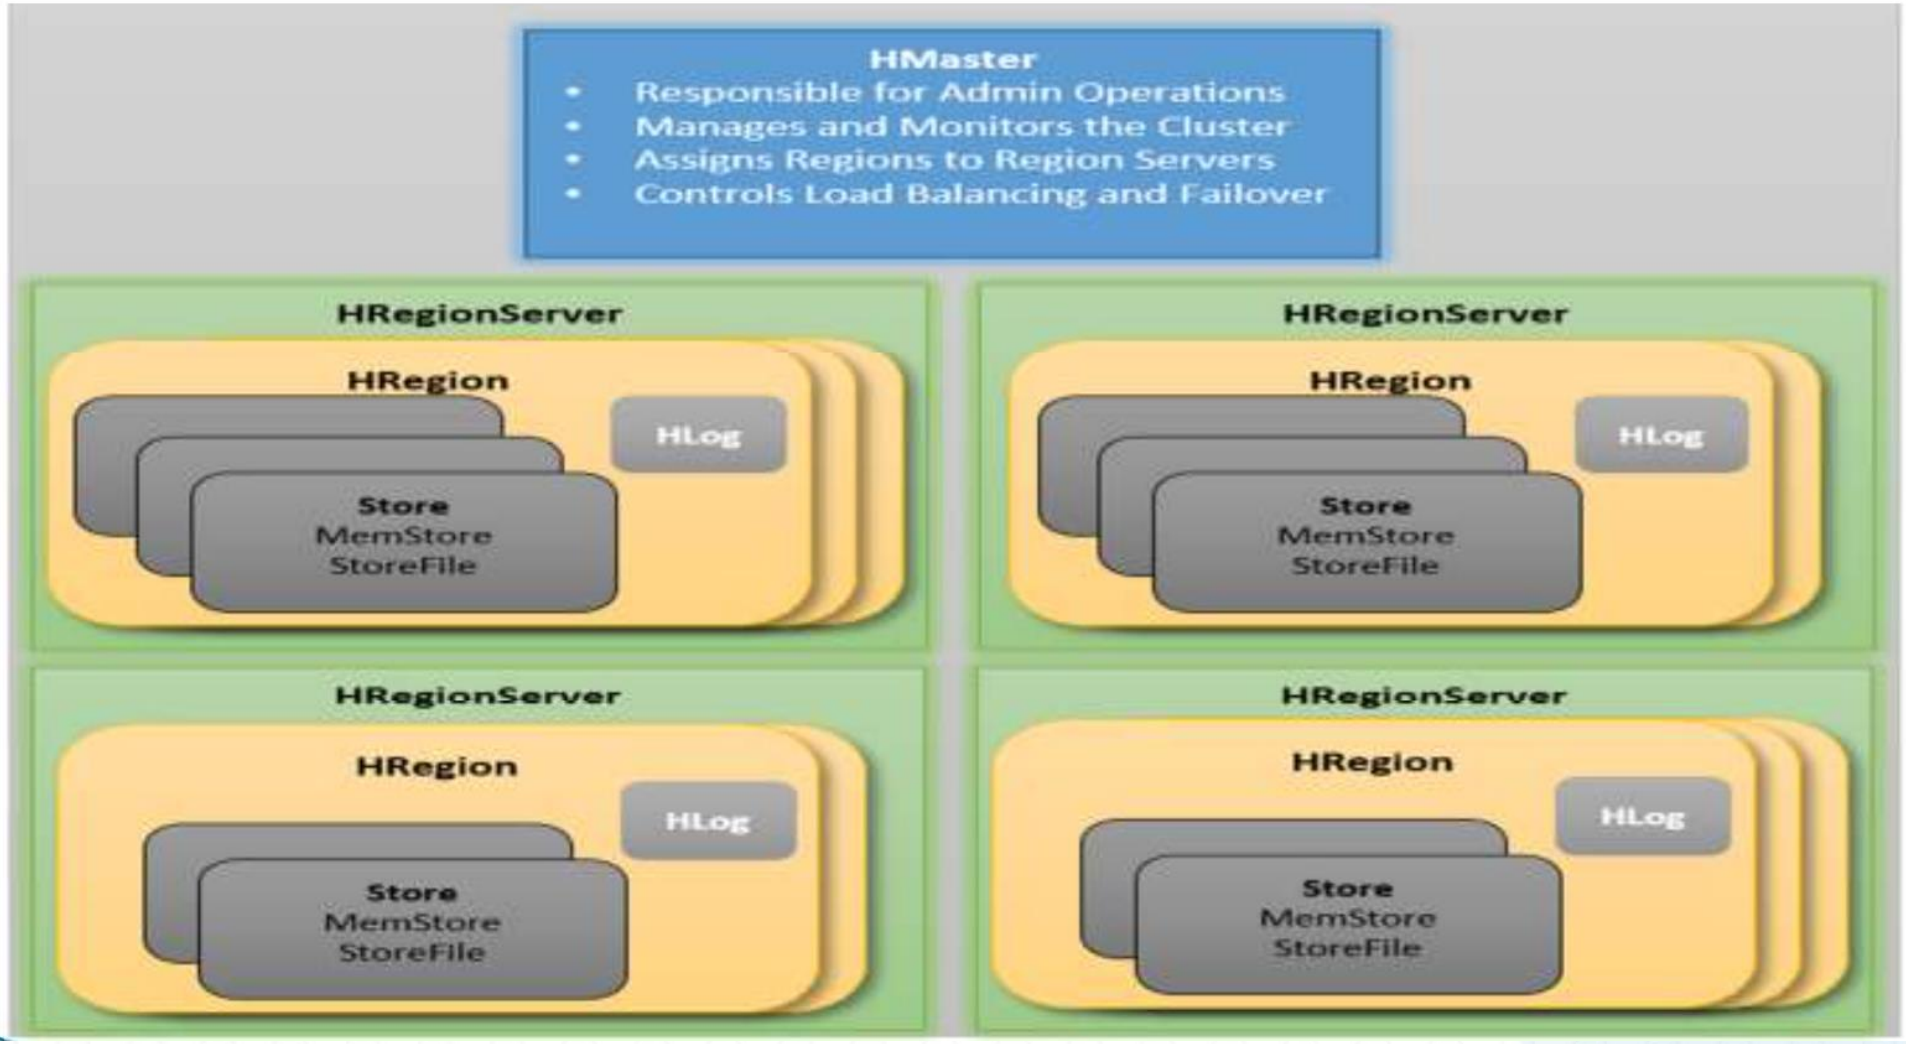
HMaster
Responsible for Admin Operations
Manages and Monitors the Cluster
Assigns Regions to Region Servers
Controls Load Balancing and Failover
HRegionServer
HRegion
HLog
Store
MemStore
StoreFile
HRegionServer
HRegion
HLog
Store
MemStore
StoreFile
HRegionServer
HRegion
HLog
Store
MemStore
StoreFile
HRegionServer
HRegion
HLog
Store
MemStore
StoreFile

Flushing & Compaction, Splitting

- Flushing
  - 大量資料寫入時將記憶體的資料寫到新的檔案
  - WAL 會Archive
- Compaction
  - 將檔案合併，將Flushing 產生的檔案合併
- Splitting
  - 檔案分割(對切)，將資料寫到另一個Region Server (會將Region Server 下線)

Compaction

- 合併多個Hfile 成一個Hfile

- 兩種類型
  - Major Compaction (完整文件合併)
  - 刪除過期與已刪除的Data
  - 一個Store 只會有一Store File
  - Minor Compaction(部分文件合併)

Compaction 優點

- 減少Hfile 個數 -> 減少IO
- 提升效能
- 刪除過期與已刪除的資料 -> 增加空間

Splitting

- 優點
  - 減少 HFile 檔案大小
  - 提高分散使用率
- 缺點:
  - Region Server Downtime (兩個Region Server Down)
  - 檔案數變多 => IO 變多

資料寫入流程

- HBase中Hfile的默認最大值(hbase.hregion.max.filesize)是256MB

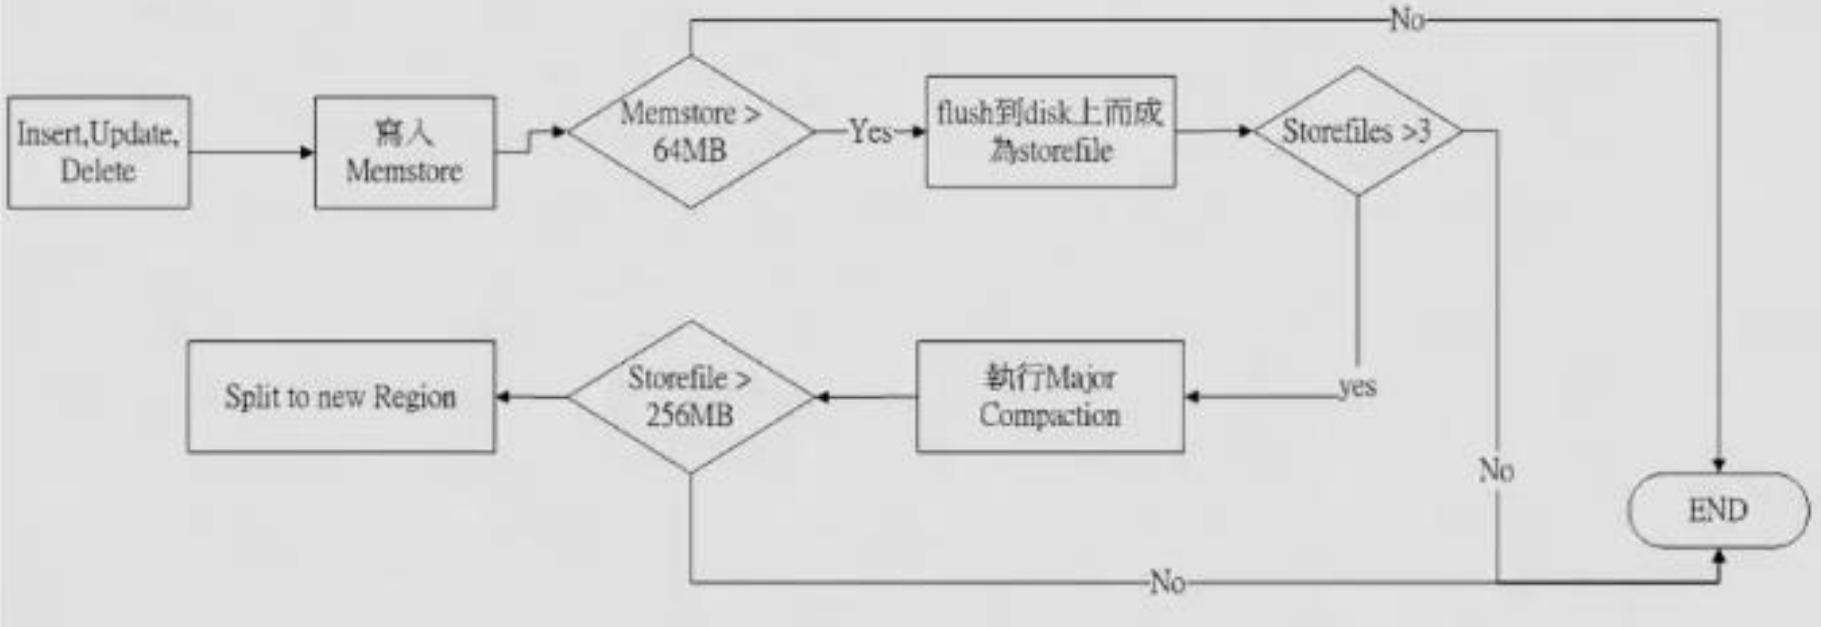

存儲模式運作

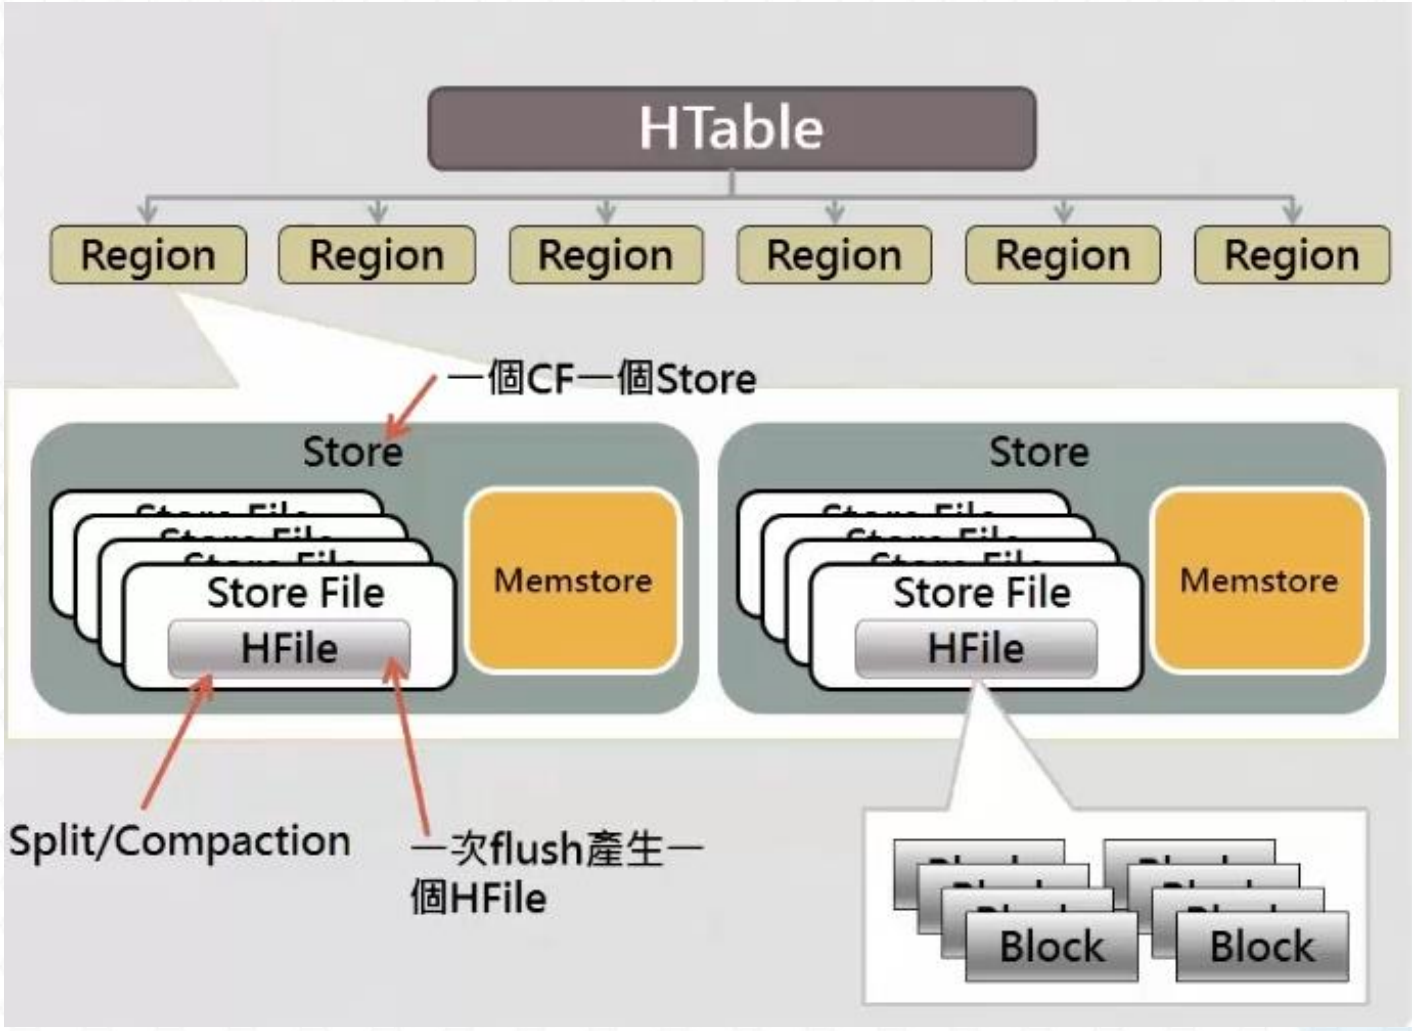
HTable
Region
Region
Region
Region
Region
Region
一個CF一個Store
Store
Store File
HFile
Memstore
Store
Store File
HFile
Memstore
Split/Compaction
一次flush產生一個HFile
Block
Block

完整HBase 架構圖

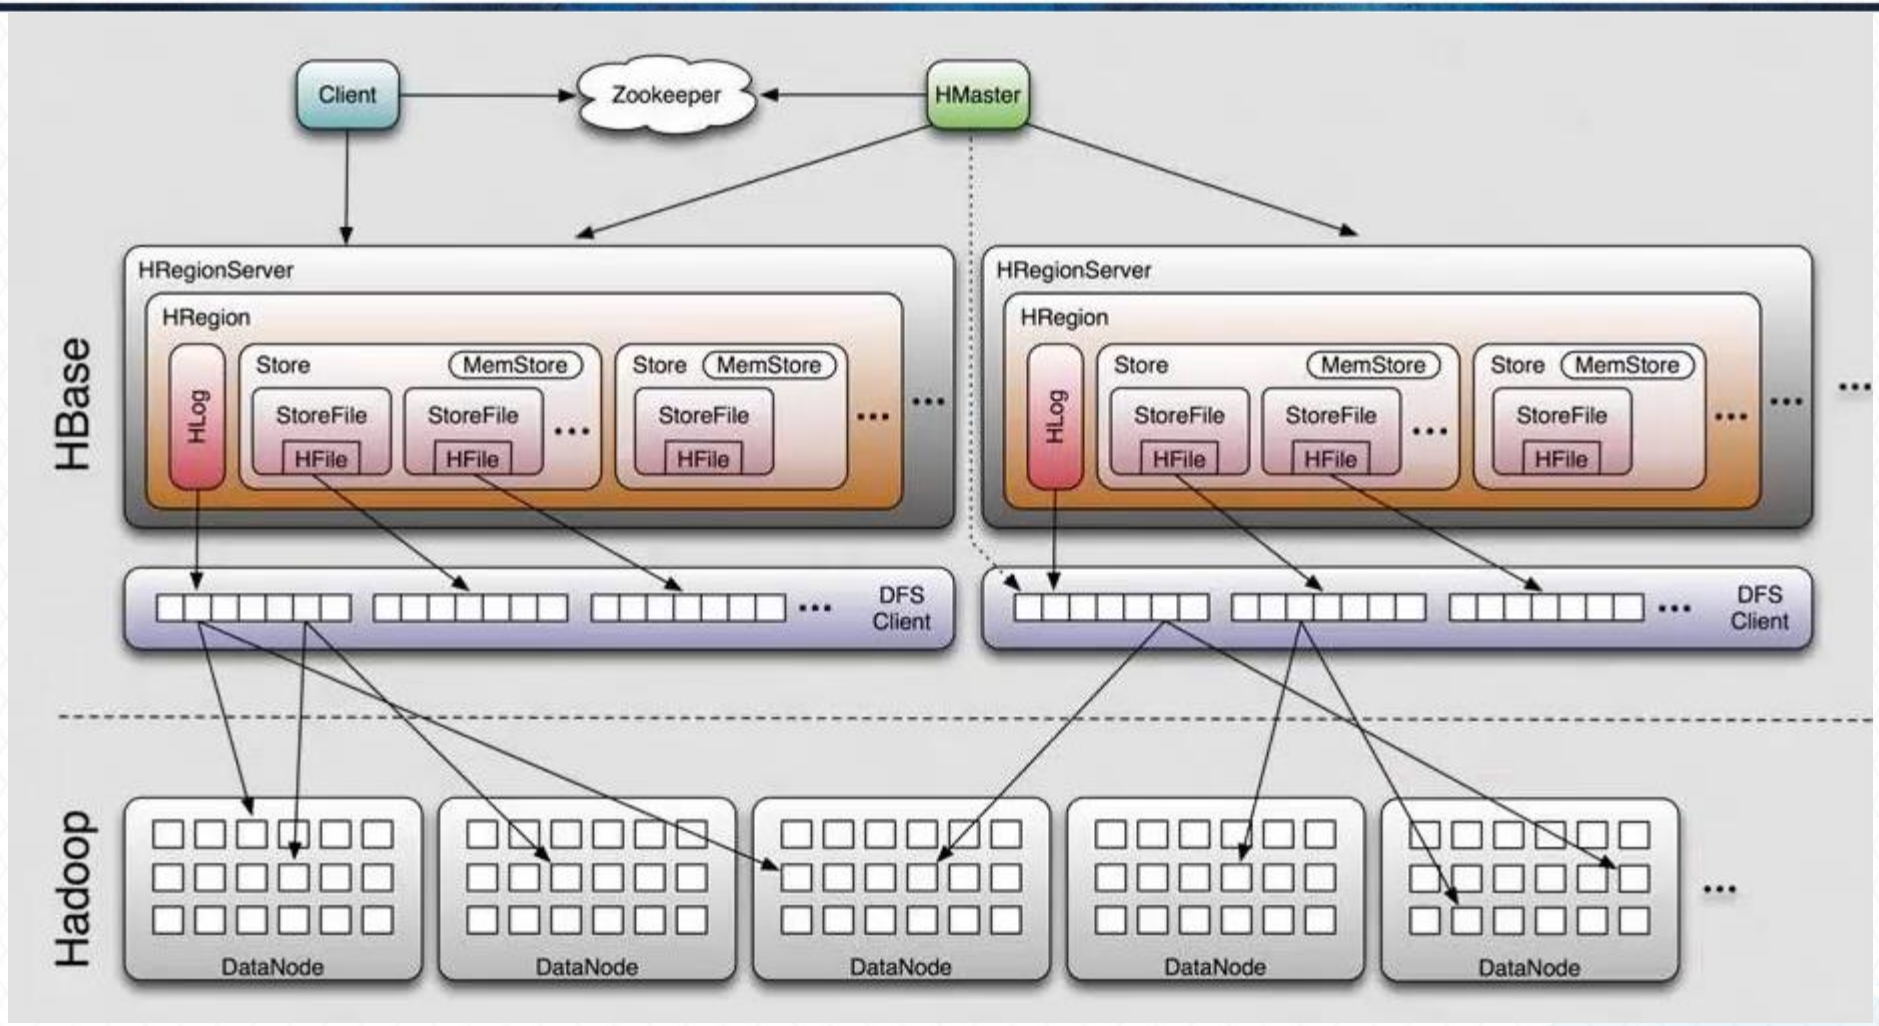
Client
Zookeeper
HMaster
HBase
HRegionServer
HRegion
HLog
Store
MemStore
StoreFile
HFile
DFS Client
Hadoop
DataNode

HBase 存儲模式

資料存放架構

- Table (HBase Table)
  - Region (Regions for the Table)
    - Store = Column Family
    - MemStore
    - StoreFile
      - ✓ Block

資料結構

- Table Terms
  - Table
  - Column Family
  - Row
  - Qualifier(Column)
  - Cell

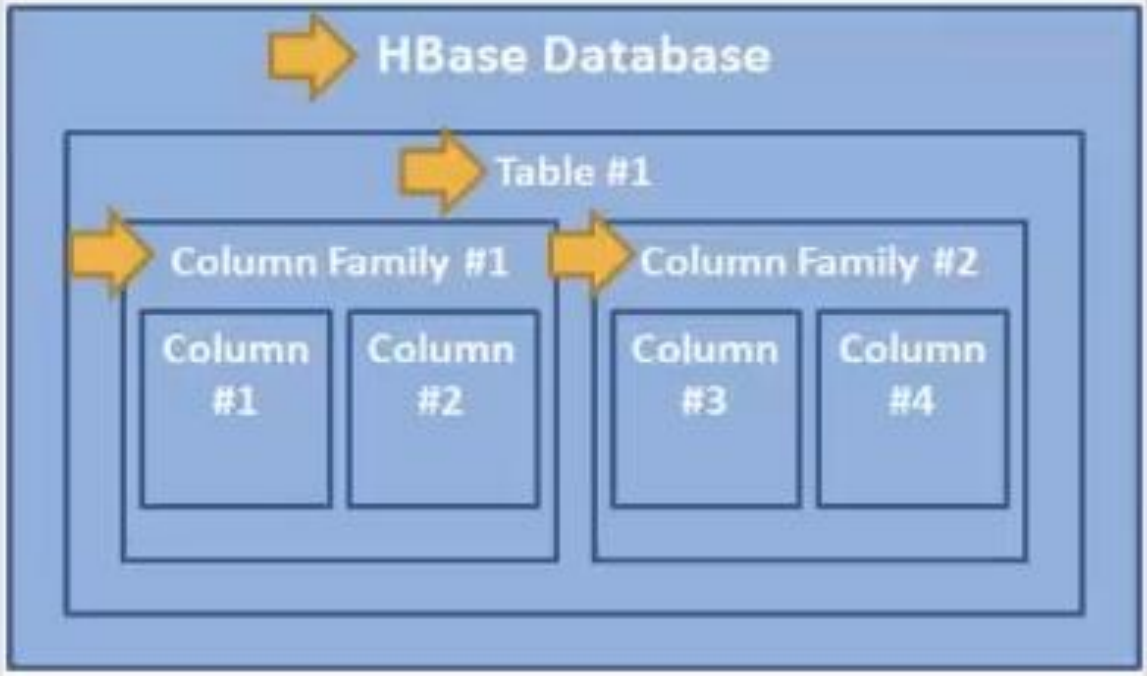

Figure 1 - HBase Data Organization

資料結構

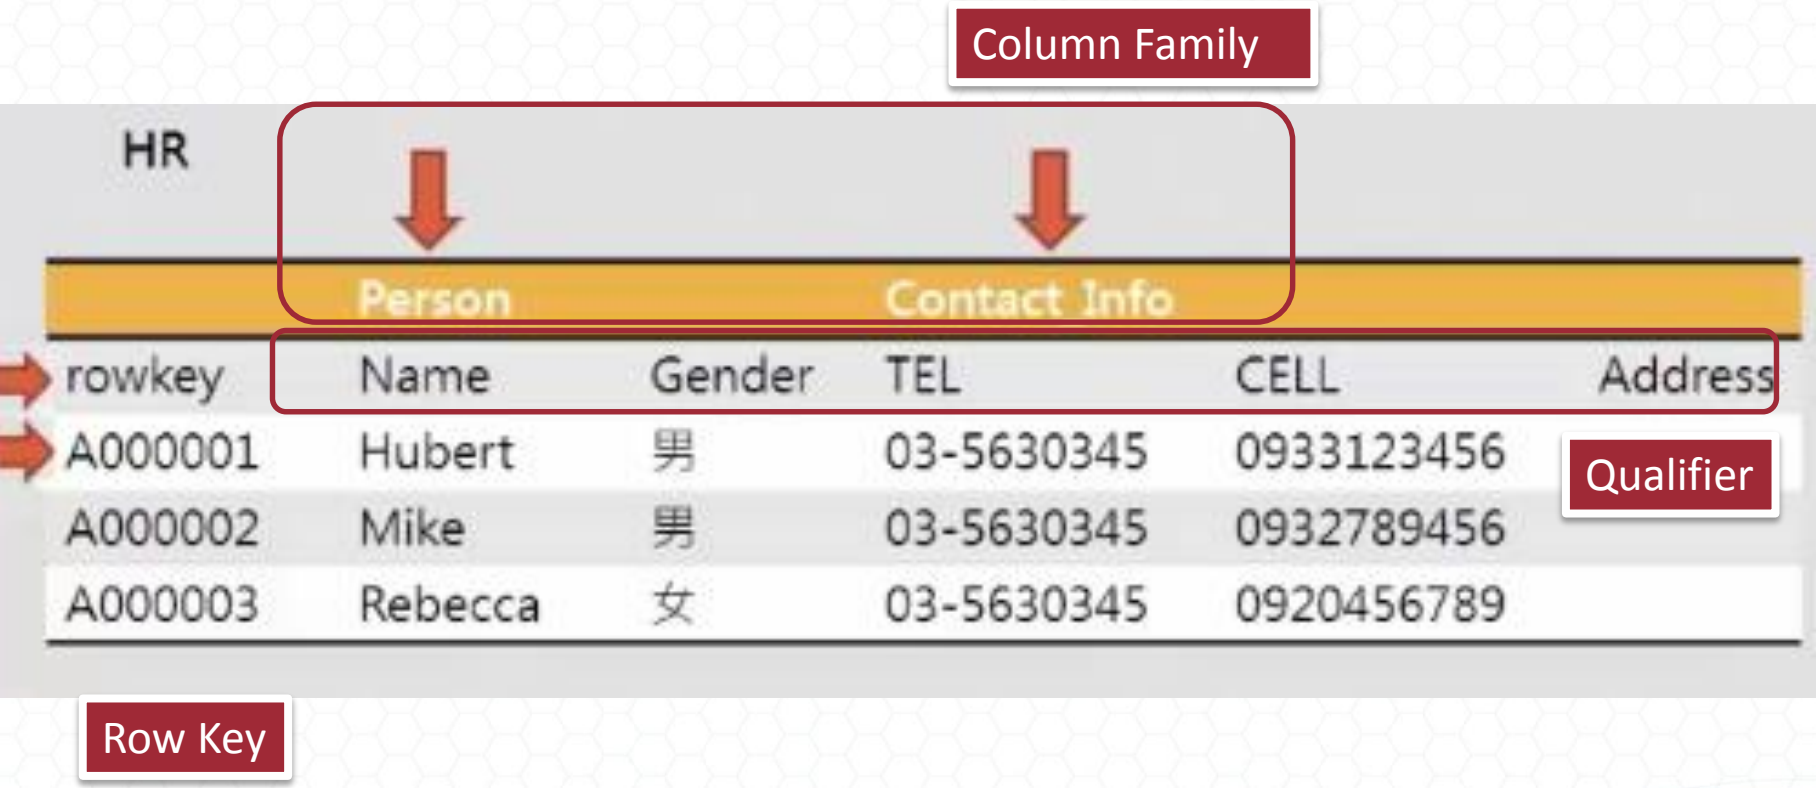
Column Family
HR
Person
Contact Info
rowkey
Name
Gender
TEL
CELL
Address
A000001
Hubert
男
03-5630345
0933123456
A000002
Mike
男
03-5630345
0932789456
A000003
Rebecca
女
03-5630345
0920456789
Qualifier
Row Key

資料結構


HBase Database
Table #N
Table #2
Table #1
Column Family #2
Column Family #1
Column #1
Column #2
Column #3
Column #4
Column #5
Row #1
Value001
Value029
Row #1
Value005
Row #1
Value009
Value015
Row #1
Value023

資料儲存範例

Row Key	Customer		Sales	
Customer Id	Name	City	Product	Amount
101	John White	Los Angeles, CA	Chairs	$400.00
102	Jane Brown	Atlanta, GA	Lamps	$200.00
103	Bill Green	Pittsburgh, PA	Desk	$500.00
104	Jack Black	St. Louis, MO	Bed	$1600.00

資料存儲

Key{row, column, timestamp} => Value

```
A00001.00 column=cf:DATE, timestamp=1317950820261, value=\x00\x00\x012\xDB\xFD\x8F\x9E
A00001.00 column=cf:FACILITY, timestamp=1317950820261, value=BSET
A00001.00 column=cf:LOT, timestamp=1317950820261, value=A00001.00
A00001.00 column=cf:OPERATOR, timestamp=1317950820261, value=andy
```

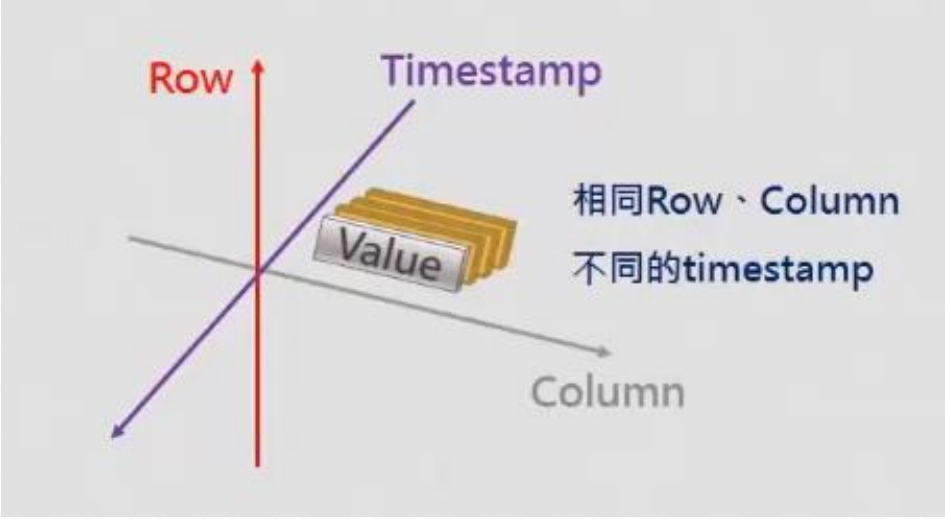

實際儲存結構

- Table Name
- Column Family Name
- Rowkey
- Qualifier

Hbase Table 只定義 Table Name 與Column Family Name，不定義Qualifier。

```
hbase(main):019:0> scan 'SaleAmount'
ROW                                   COLUMN+CELL
 A001                                 column=Product:Drive_Side, timestamp=1385472194283, value=Left
 A001                                 column=Product:Product_ID, timestamp=1385472194178, value=C200
 A001                                 column=Sale_Amount:China, timestamp=1385472194220, value=8000
 A001                                 column=Sale_Amount:Taiwan, timestamp=1385472194330, value=1000
 A002                                 column=Product:Drive_Side, timestamp=1385472194378, value=Left
 A002                                 column=Product:Product_ID, timestamp=1385472194429, value=C300
 A002                                 column=Sale_Amount:China, timestamp=1385472194468, value=6000
 A003                                 column=Product:Drive_Side, timestamp=1385472869841, value=Right
 A003                                 column=Product:Product_ID, timestamp=1385472869913, value=E300
 A003                                 column=Sale_Amount:China, timestamp=1385472869959, value=200
 A003                                 column=Sale_Amount:Japan, timestamp=1385472870007, value=3000
3 row(s) in 0.0280 seconds
```

Schema 設計原則

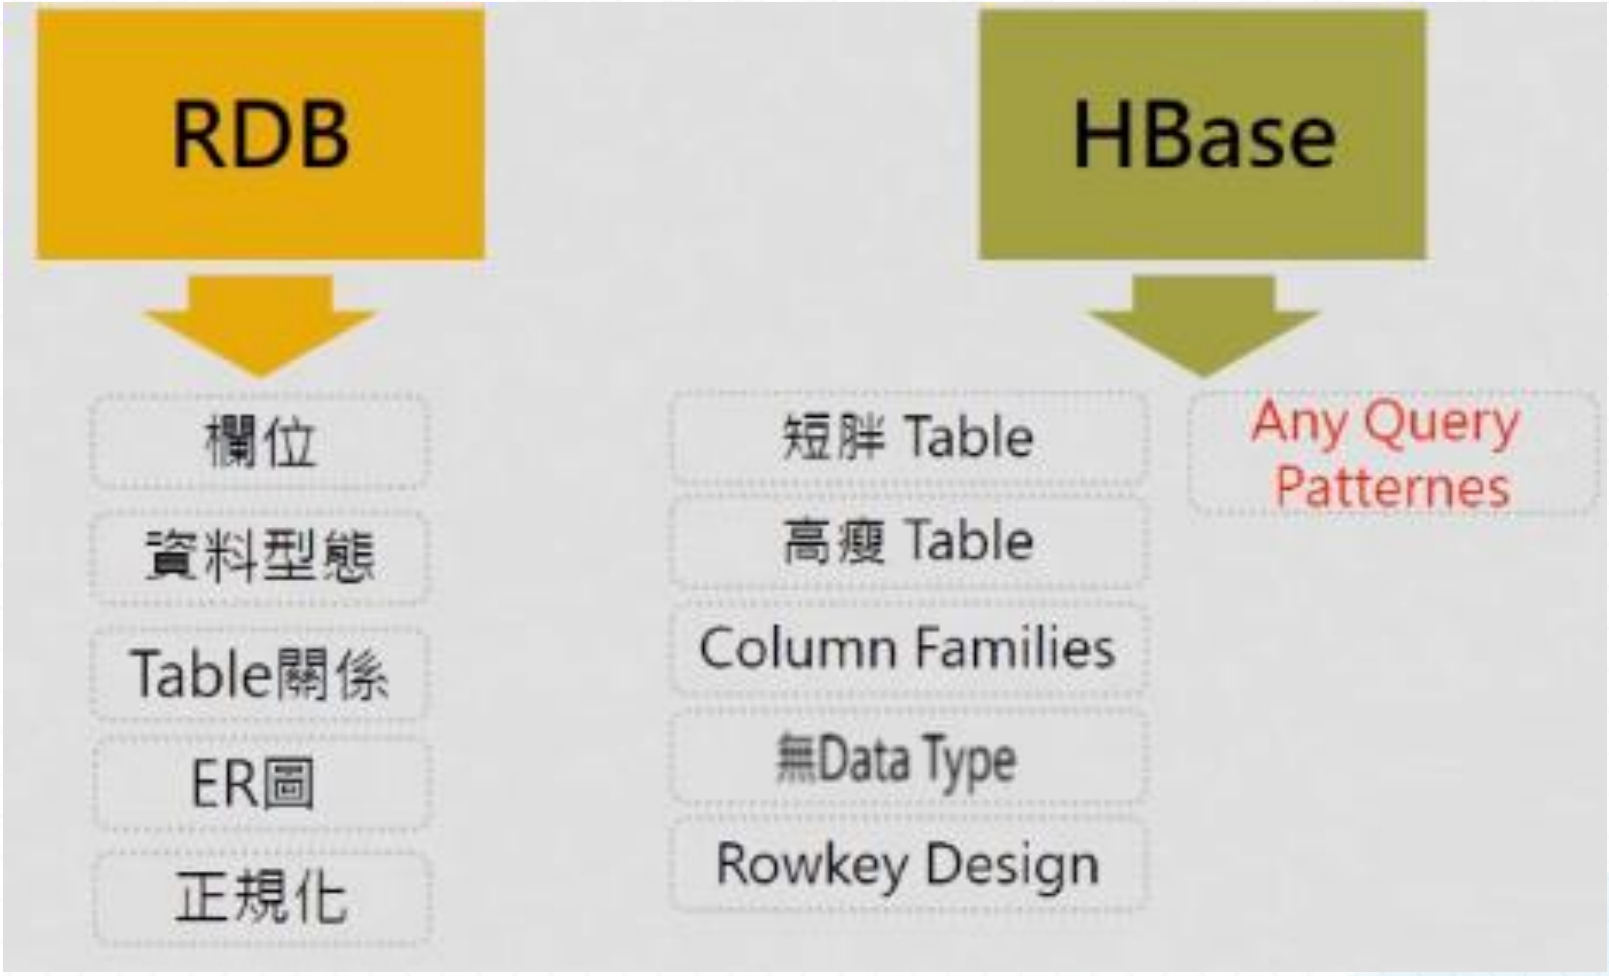
RDB
欄位
資料型態
Table關係
ER圖
正規化
HBase
短胖 Table
高瘦 Table
Column Families
無Data Type
Rowkey Design
Any Query Patternes

DDI 原則

- De-normalization
- Duplication
- Intelligent key

避免HotSpot

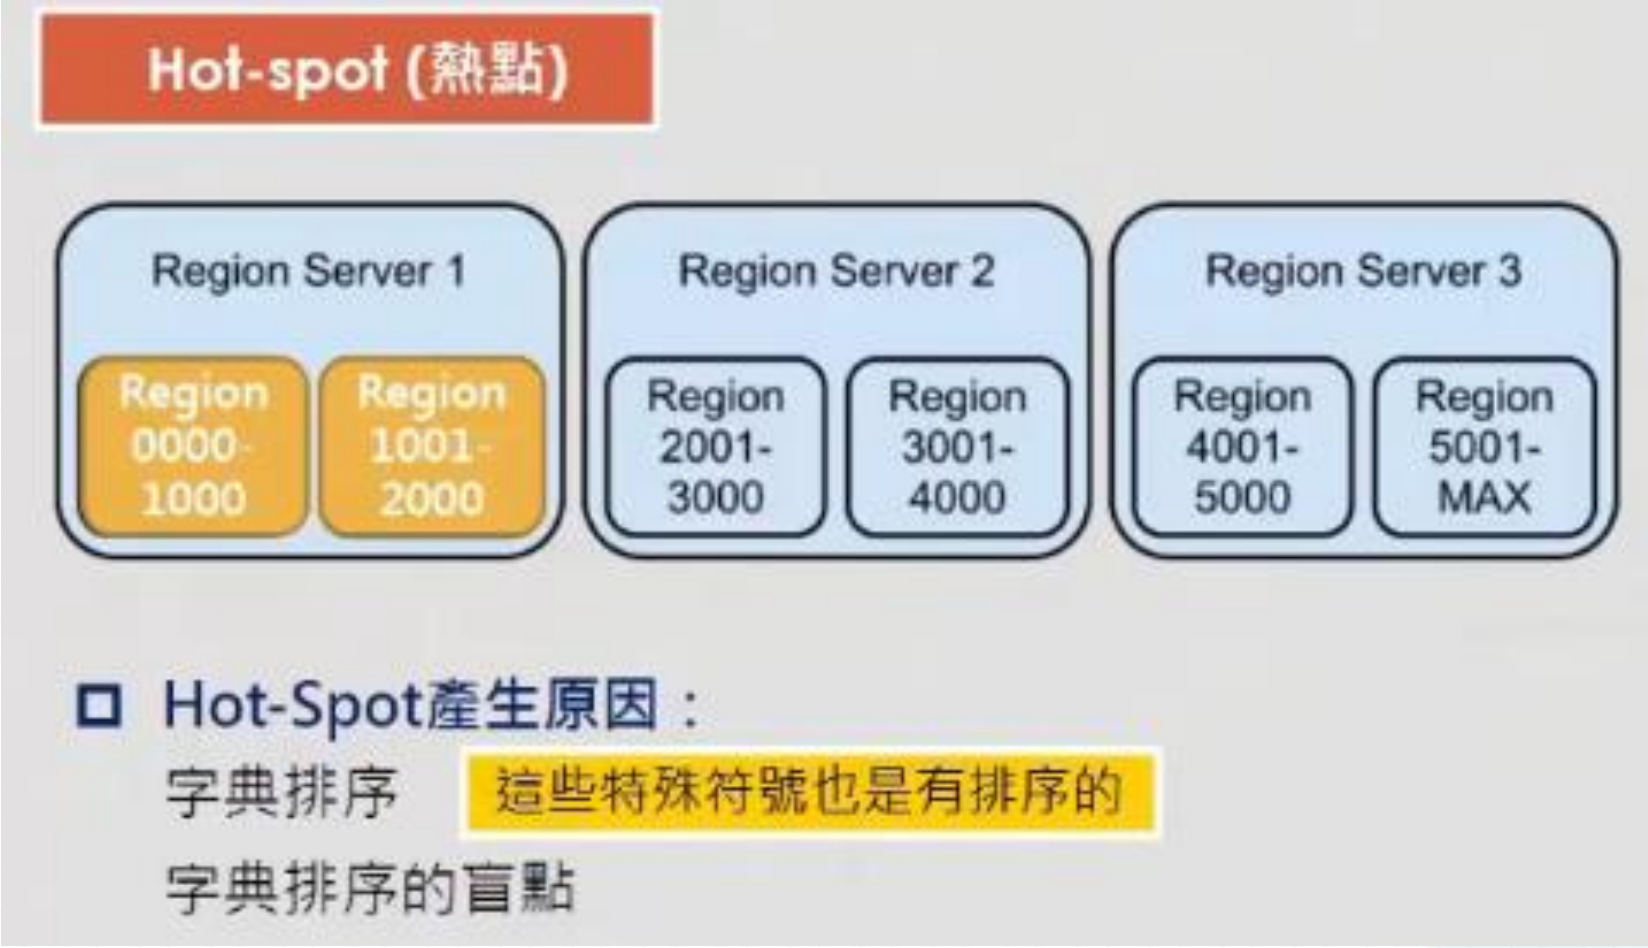
Hot-spot (熱點)
Region Server 1
Region 0000-1000
Region 1001-2000
Region Server 2
Region 2001-3000
Region 3001-4000
Region Server 3
Region 4001-5000
Region 5001-MAX
Hot-Spot產生原因：
字典排序
這些特殊符號也是有排序的
字典排序的盲點

避免HotSpot 的做法

Time Series Data

① **Salting：**

資料前面加特殊演算法產生的字串

② **Field swap/promotion：**

例如Google搜尋引擎的作法

③ **Randomization：**

隨機，加上一個ND5的編碼

HBase 實做

Hbase Shell

檢查狀態	• hbase> status
檢查版本	• hbase> version
檢查跟表格相關說明	• hbase> table_help
使用者資訊	• hbase> whoami

Hbase DDL 指令

- 啟用表格
  - Syntax :
  - enable ‘table-name’
  - Example :
  - enable ‘easylearning’
- 確認表格啟用
  - Syntax :
  - is_enabled ‘table-name’
  - Example :
  - is_enabled ‘easylearning’

Hbase DDL 指令

- 停止使用表格
  - Syntax :
  - disable ‘table-name’
  - Example :
  - disable ‘easylearning’
- 確認表格停止
  - Syntax :
  - is_disabled ‘table-name’
  - Example :
  - is_disabled ‘easylearning’

Hbase DDL 指令

- 建立表格
  - Syntax :
  - create ‘table-name’ , { NAME=>‘column-family-name’ } , { NAME=>‘column-family-name’ }
  - Example :
  - create ‘easylearning’ , {NAME=> ’Student’} , {NAME => ’Teacher’}
- 檢視表格
  - Syntax :
  - describe ‘table-name’
  - Example :
  - describe ‘easylearning’
- 表列所有表格
  - Syntax :
  - list

Hbase DDL 指令

- 確認表格是否存在
  - Syntax :
  - exists ‘table_name’
  - Example:
  - exists ‘easylearning’
- 刪除表格
  - Syntax :
  - drop ‘table_name’
  - Example :
  - disable ‘easylearning’
  - drop ‘easylearning’

Hbase DDL 指令

- 刪除Column Family
  - Syntax:
  - alter ‘ table name ’, ‘delete’ ⇒ ‘ column family ’
  - Example:
  - alter ‘easylearning’, ‘delete’ ⇒ ‘student’

Hbase DML 指令

- 新增資料
  - Syntax :
  - put ‘table-name’ , ‘Row-Key’ , ‘Colum-family-name : column-name’ , ’value to be inserted’
  - Example :
  - put ‘easylearning’ , ‘stud-101’ , ‘Student : stud_name’ , ‘Alice’
- 取得資料內容
  - Syntax :
  - get ’<table name>’,’row1’
  - Example :
  - get ‘easylearning’, ‘stud-101’

Hbase DML 指令

- 刪除Cell 資料
  - Syntax :
  - delete ‘<table name>’, ‘<row>’, ‘< Colum-family-name : column name >’, ‘<timestamp>’
  - Example :
  - delete ‘easylearning', ‘stud-101', ‘Student : stud_name’, 1417521848375
- 刪除全部資料
  - Syntax :
  - deleteall ‘<table name>’, ‘<row>’
  - Example :
  - deleteall ‘easylearning’, ‘stud-101’

Hbase DML 指令

- 取得特定表格資料
  - Syntax :
  - scan ‘table-name’
  - Example :
  - scan ‘easylearning’
- 計算列數
  - Syntax :
  - count ‘table-name’
  - Example :
  - count ‘easylearning’

Hbase DML 指令

- 重建表格
  - Syntax :
  - truncate ‘table-name’
  - Example :
  - truncate ‘easylearning’

THANK YOU